

Метод сопряжённых градиентов

МЕТОДЫ ВЫПУКЛОЙ ОПТИМИЗАЦИИ

НЕДЕЛЯ 9

Даня Меркулов
Пётр Остроухов



Даня Меркулов, Петр Остроухов

Оптимизация для всех! ЦУ



Квадратичная задача оптимизации

Сильно выпуклая квадратичная функция



Рассмотрим следующую квадратичную задачу оптимизации:

Условия оптимальности

$$\min_{x \in \mathbb{R}^n} f(x) = \min_{x \in \mathbb{R}^n} \frac{1}{2} x^\top A x - b^\top x + c, \text{ где } A \in \mathbb{S}_{++}^n.$$

(1)

$$A x^* = b$$

Steepest Descent



Conjugate Gradient



Наискорейший спуск aka точный линейный поиск



$$\alpha_k = \arg \min_{\alpha \in \mathbb{R}^+} f(x_{k+1}) = \arg \min_{\alpha \in \mathbb{R}^+} f(x_k - \alpha \nabla f(x_k))$$

Более теоретический, чем практический подход к выбору шага. Он также позволяет анализировать сходимость, но точный линейный поиск может быть численно сложным, если вычисление функции занимает слишком много времени или требует слишком много ресурсов.

Интересное теоретическое свойство этого метода заключается в том, что каждая следующая итерация метода ортогональна предыдущей:

$$\alpha_k = \arg \min_{\alpha \in \mathbb{R}^+} f(x_k - \alpha \nabla f(x_k))$$

Наискорейший спуск aka точный линейный поиск



$$\alpha_k = \arg \min_{\alpha \in \mathbb{R}^+} f(x_{k+1}) = \arg \min_{\alpha \in \mathbb{R}^+} f(x_k - \alpha \nabla f(x_k))$$

Более теоретический, чем практический подход к выбору шага. Он также позволяет анализировать сходимость, но точный линейный поиск может быть численно сложным, если вычисление функции занимает слишком много времени или требует слишком много ресурсов.

Интересное теоретическое свойство этого метода заключается в том, что каждая следующая итерация метода ортогональна предыдущей:

$$\alpha_k = \arg \min_{\alpha \in \mathbb{R}^+} f(x_k - \alpha \nabla f(x_k))$$

Условия оптимальности:

Наискорейший спуск aka точный линейный поиск



$$\alpha_k = \arg \min_{\alpha \in \mathbb{R}^+} f(x_{k+1}) = \arg \min_{\alpha \in \mathbb{R}^+} f(x_k - \alpha \nabla f(x_k))$$

Более теоретический, чем практический подход к выбору шага. Он также позволяет анализировать сходимость, но точный линейный поиск может быть численно сложным, если вычисление функции занимает слишком много времени или требует слишком много ресурсов.

Интересное теоретическое свойство этого метода заключается в том, что каждая следующая итерация метода ортогональна предыдущей:

$$\alpha_k = \arg \min_{\alpha \in \mathbb{R}^+} f(x_k - \alpha \nabla f(x_k))$$

Условия оптимальности:

$$\nabla f(x_k)^T \nabla f(x_{k+1}) = 0$$



Оптимальное значение для квадратичных функций

$$\nabla f(x_k)^T A(x_k - \alpha \nabla f(x_k)) - \nabla f(x_k)^T b = 0 \quad \alpha_k = \frac{\nabla f(x_k)^T \nabla f(x_k)}{\nabla f(x_k)^T A \nabla f(x_k)}$$



Рисунок 1.
Наискорейший спуск

Открыть в Colab

Ортогональность

Сопряженные направления. A -ортогональность.



v_1 and v_2 are orthogonal

$$v_1^T v_2 = 0.00$$


$$v_1^T A v_2 = 1.19$$



\hat{v}_1 and \hat{v}_2 are A -orthogonal

$$\hat{v}_1^T \hat{v}_2 = -0.80$$

$$\hat{v}_1^T A \hat{v}_2 = -0.00$$



Сопряженные направления. A -ортогональность.



Предположим, у нас есть две системы координат и квадратичная функция $f(x) = \frac{1}{2}x^T I x$ выглядит так, как на левой части изображения 2, в то время как в других координатах она выглядит как $f(\hat{x}) = \frac{1}{2}\hat{x}^T A \hat{x}$, где $A \in \mathbb{S}_{++}^n$.

$$\frac{1}{2}x^T I x$$

$$\frac{1}{2}\hat{x}^T A \hat{x}$$

Поскольку $A = Q \Lambda Q^T$:

$$\frac{1}{2}\hat{x}^T A \hat{x}$$

Сопряженные направления. A -ортогональность.



Предположим, у нас есть две системы координат и квадратичная функция $f(x) = \frac{1}{2}x^T I x$ выглядит так, как на левой части изображения 2, в то время как в других координатах она выглядит как $f(\hat{x}) = \frac{1}{2}\hat{x}^T A \hat{x}$, где $A \in \mathbb{S}_{++}^n$.

$$\frac{1}{2}x^T I x$$

$$\frac{1}{2}\hat{x}^T A \hat{x}$$

Поскольку $A = Q\Lambda Q^T$:

$$\frac{1}{2}\hat{x}^T A \hat{x} = \frac{1}{2}\hat{x}^T Q\Lambda Q^T \hat{x}$$

Сопряженные направления. A -ортогональность.



Предположим, у нас есть две системы координат и квадратичная функция $f(x) = \frac{1}{2}x^T I x$ выглядит так, как на левой части изображения 2, в то время как в других координатах она выглядит как $f(\hat{x}) = \frac{1}{2}\hat{x}^T A \hat{x}$, где $A \in \mathbb{S}_{++}^n$.

$$\frac{1}{2}x^T I x$$

$$\frac{1}{2}\hat{x}^T A \hat{x}$$

Поскольку $A = Q\Lambda Q^T$:

$$\frac{1}{2}\hat{x}^T A \hat{x} = \frac{1}{2}\hat{x}^T Q\Lambda Q^T \hat{x} = \frac{1}{2}\hat{x}^T Q\Lambda^{\frac{1}{2}}\Lambda^{\frac{1}{2}}Q^T \hat{x}$$

Сопряженные направления. A -ортогональность.



Предположим, у нас есть две системы координат и квадратичная функция $f(x) = \frac{1}{2}x^T I x$ выглядит так, как на левой части изображения 2, в то время как в других координатах она выглядит как $f(\hat{x}) = \frac{1}{2}\hat{x}^T A \hat{x}$, где $A \in \mathbb{S}_{++}^n$.

$$\frac{1}{2}x^T I x$$

$$\frac{1}{2}\hat{x}^T A \hat{x}$$

Поскольку $A = Q \Lambda Q^T$:

$$\frac{1}{2}\hat{x}^T A \hat{x} = \frac{1}{2}\hat{x}^T Q \Lambda Q^T \hat{x} = \frac{1}{2}\hat{x}^T Q \Lambda^{\frac{1}{2}} \Lambda^{\frac{1}{2}} Q^T \hat{x} = \frac{1}{2}x^T I x$$

Сопряженные направления. A -ортогональность.



Предположим, у нас есть две системы координат и квадратичная функция $f(x) = \frac{1}{2}x^T I x$ выглядит так, как на левой части изображения 2, в то время как в других координатах она выглядит как $f(\hat{x}) = \frac{1}{2}\hat{x}^T A \hat{x}$, где $A \in \mathbb{S}_{++}^n$.

$$\frac{1}{2}x^T I x$$

$$\frac{1}{2}\hat{x}^T A \hat{x}$$

Поскольку $A = Q\Lambda Q^T$:

$$\frac{1}{2}\hat{x}^T A \hat{x} = \frac{1}{2}\hat{x}^T Q\Lambda Q^T \hat{x} = \frac{1}{2}\hat{x}^T Q\Lambda^{\frac{1}{2}}\Lambda^{\frac{1}{2}}Q^T \hat{x} = \frac{1}{2}x^T I x \text{ и } \hat{x} = Q\Lambda^{-\frac{1}{2}}x$$

Сопряженные направления. A -ортогональность.



Предположим, у нас есть две системы координат и квадратичная функция $f(x) = \frac{1}{2}x^T I x$ выглядит так, как на левой части изображения 2, в то время как в других координатах она выглядит как $f(\hat{x}) = \frac{1}{2}\hat{x}^T A \hat{x}$, где $A \in \mathbb{S}_{++}^n$.

$$\frac{1}{2}x^T I x$$

$$\frac{1}{2}\hat{x}^T A \hat{x}$$

Поскольку $A = Q\Lambda Q^T$:

$$\frac{1}{2}\hat{x}^T A \hat{x} = \frac{1}{2}\hat{x}^T Q\Lambda Q^T \hat{x} = \frac{1}{2}\hat{x}^T Q\Lambda^{\frac{1}{2}}\Lambda^{\frac{1}{2}}Q^T \hat{x} = \frac{1}{2}x^T I x \text{ и } \hat{x} = Q\Lambda^{-\frac{1}{2}}x$$

Сопряженные направления. A -ортогональность.



Предположим, у нас есть две системы координат и квадратичная функция $f(x) = \frac{1}{2}x^T I x$ выглядит так, как на левой части изображения 2, в то время как в других координатах она выглядит как $f(\hat{x}) = \frac{1}{2}\hat{x}^T A \hat{x}$, где $A \in \mathbb{S}_{++}^n$.

$$\frac{1}{2}x^T I x$$

$$\frac{1}{2}\hat{x}^T A \hat{x}$$

Поскольку $A = Q\Lambda Q^T$:

$$\frac{1}{2}\hat{x}^T A \hat{x} = \frac{1}{2}\hat{x}^T Q\Lambda Q^T \hat{x} = \frac{1}{2}\hat{x}^T Q\Lambda^{\frac{1}{2}}\Lambda^{\frac{1}{2}}Q^T \hat{x} = \frac{1}{2}x^T I x \text{ и } \hat{x} = Q\Lambda^{-\frac{1}{2}}x$$

A -ортогональные векторы

Векторы $x \in \mathbb{R}^n$ и $y \in \mathbb{R}^n$ называются A -ортогональными (или A -сопряженными), если

$$x^T A y = 0 \quad \Leftrightarrow \quad x \perp_A y$$

Когда $A = I$, A -ортогональность превращается в ортогональность.

Процесс Грама-Шмидта



Вход: n линейно независимых векторов u_0, \dots, u_{n-1} .

Выход: n линейно независимых попарно ортогональных векторов d_0, \dots, d_{n-1} .



Рисунок 3. Иллюстрация процесса Грама-Шмидта

Процесс Грама-Шмидта



Вход: n линейно независимых векторов u_0, \dots, u_{n-1} .

Выход: n линейно независимых попарно ортогональных векторов d_0, \dots, d_{n-1} .



Рисунок 4. Иллюстрация процесса Грама-Шмидта

Процесс Грама-Шмидта



Вход: n линейно независимых векторов u_0, \dots, u_{n-1} .

Выход: n линейно независимых попарно ортогональных векторов d_0, \dots, d_{n-1} .



Рисунок 5. Иллюстрация процесса Грама-Шмидта

Процесс Грама-Шмидта



Вход: n линейно независимых векторов u_0, \dots, u_{n-1} .

Выход: n линейно независимых попарно ортогональных векторов d_0, \dots, d_{n-1} .



Рисунок 6. Иллюстрация процесса Грама-Шмидта

Процесс Грама-Шмидта



Вход: n линейно независимых векторов u_0, \dots, u_{n-1} .

Выход: n линейно независимых попарно ортогональных векторов d_0, \dots, d_{n-1} .



Рисунок 7. Иллюстрация процесса Грама-Шмидта

Процесс Грама-Шмидта



Вход: n линейно независимых векторов u_0, \dots, u_{n-1} .



Процесс Грама-Шмидта



Вход: n линейно независимых векторов u_0, \dots, u_{n-1} .

Выход: n линейно независимых попарно ортогональных векторов d_0, \dots, d_{n-1} .

$$d_0 = u_0$$



$$\pi_d(u) = \frac{\langle d, u \rangle}{\|d\|_2^2} d$$

Процесс Грама-Шмидта



Вход: n линейно независимых векторов u_0, \dots, u_{n-1} .

Выход: n линейно независимых попарно ортогональных векторов d_0, \dots, d_{n-1} .



$$d_0 = u_0$$

$$d_1 = u_1 - \pi_{d_0}(u_1)$$



$$\pi_d(u) = \frac{\langle d, u \rangle}{\|d\|_2^2} d$$

Процесс Грама-Шмидта



Вход: n линейно независимых векторов u_0, \dots, u_{n-1} .

Выход: n линейно независимых попарно ортогональных векторов d_0, \dots, d_{n-1} .



$$d_0 = u_0$$

$$d_1 = u_1 - \pi_{d_0}(u_1)$$

$$d_2 = u_2 - \pi_{d_0}(u_2) - \pi_{d_1}(u_2)$$



$$\pi_d(u) = \frac{\langle d, u \rangle}{\|d\|_2^2} d$$

Процесс Грама-Шмидта



Вход: n линейно независимых векторов u_0, \dots, u_{n-1} .

Выход: n линейно независимых попарно ортогональных векторов d_0, \dots, d_{n-1} .



$$d_0 = u_0$$

$$d_1 = u_1 - \pi_{d_0}(u_1)$$

$$d_2 = u_2 - \pi_{d_0}(u_2) - \pi_{d_1}(u_2)$$

\vdots



$$\pi_d(u) = \frac{\langle d, u \rangle}{\|d\|_2^2} d$$

Процесс Грама-Шмидта



Вход: n линейно независимых векторов u_0, \dots, u_{n-1} .

Выход: n линейно независимых попарно ортогональных векторов d_0, \dots, d_{n-1} .



$$d_0 = u_0$$

$$d_1 = u_1 - \pi_{d_0}(u_1)$$

$$d_2 = u_2 - \pi_{d_0}(u_2) - \pi_{d_1}(u_2)$$

\vdots

$$d_k = u_k - \sum_{i=0}^{k-1} \pi_{d_i}(u_k)$$



$$\pi_d(u) = \frac{\langle d, u \rangle}{\|d\|_2^2} d$$

Процесс Грама-Шмидта



Вход: n линейно независимых векторов u_0, \dots, u_{n-1} .

Выход: n линейно независимых попарно ортогональных векторов d_0, \dots, d_{n-1} .



$$d_0 = u_0$$

$$d_1 = u_1 - \pi_{d_0}(u_1)$$

$$d_2 = u_2 - \pi_{d_0}(u_2) - \pi_{d_1}(u_2)$$

\vdots

$$d_k = u_k - \sum_{i=0}^{k-1} \pi_{d_i}(u_k)$$



$$\pi_d(u) = \frac{\langle d, u \rangle}{\|d\|_2^2} d$$

Процесс Грама-Шмидта



Вход: n линейно независимых векторов u_0, \dots, u_{n-1} .

Выход: n линейно независимых попарно ортогональных векторов d_0, \dots, d_{n-1} .



$$\pi_d(u) = \frac{\langle d, u \rangle}{\|d\|_2^2} d$$

$$d_0 = u_0$$

$$d_1 = u_1 - \pi_{d_0}(u_1)$$

$$d_2 = u_2 - \pi_{d_0}(u_2) - \pi_{d_1}(u_2)$$

\vdots

$$d_k = u_k - \sum_{i=0}^{k-1} \pi_{d_i}(u_k)$$

$$d_k = u_k + \sum_{i=0}^{k-1} \beta_{ik} d_i \quad \beta_{ik} = -\frac{\langle d_i, u_k \rangle}{\langle d_i, d_i \rangle} \quad (2)$$

Метод сопряженных направлений (CD)

Общая идея



- В изотропном случае $A = I$ метод наискорейшего спуска, запущенный из произвольной точки в n ортогональных линейно независимых направлениях, сойдется за n шагов в точных арифметических вычислениях. Мы пытаемся построить аналогичную процедуру в случае $A \neq I$ с использованием концепции A -ортогональности.

Общая идея



- В изотропном случае $A = I$ метод наискорейшего спуска, запущенный из произвольной точки в n ортогональных линейно независимых направлениях, сойдется за n шагов в точных арифметических вычислениях. Мы пытаемся построить аналогичную процедуру в случае $A \neq I$ с использованием концепции A -ортогональности.
- Предположим, у нас есть набор из n линейно независимых A -ортогональных направлений d_0, \dots, d_{n-1} (которые будут вычислены с помощью процесса Грама-Шмидта).

Общая идея



- В изотропном случае $A = I$ метод наискорейшего спуска, запущенный из произвольной точки в n ортогональных линейно независимых направлениях, сойдется за n шагов в точных арифметических вычислениях. Мы пытаемся построить аналогичную процедуру в случае $A \neq I$ с использованием концепции A -ортогональности.
- Предположим, у нас есть набор из n линейно независимых A -ортогональных направлений d_0, \dots, d_{n-1} (которые будут вычислены с помощью процесса Грама-Шмидта).
- Мы хотим построить метод, который идет из x_0 в x^* для квадратичной задачи с шагами α_i , который, фактически, является разложением $x^* - x_0$ в некотором базисе:

$$x^* = x_0 + \sum_{i=0}^{n-1} \alpha_i d_i \quad x^* - x_0 = \sum_{i=0}^{n-1} \alpha_i d_i$$

Общая идея



- В изотропном случае $A = I$ метод наискорейшего спуска, запущенный из произвольной точки в n ортогональных линейно независимых направлениях, сойдется за n шагов в точных арифметических вычислениях. Мы пытаемся построить аналогичную процедуру в случае $A \neq I$ с использованием концепции A -ортогональности.
- Предположим, у нас есть набор из n линейно независимых A -ортогональных направлений d_0, \dots, d_{n-1} (которые будут вычислены с помощью процесса Грама-Шмидта).
- Мы хотим построить метод, который идет из x_0 в x^* для квадратичной задачи с шагами α_i , который, фактически, является разложением $x^* - x_0$ в некотором базисе:

$$x^* = x_0 + \sum_{i=0}^{n-1} \alpha_i d_i \quad x^* - x_0 = \sum_{i=0}^{n-1} \alpha_i d_i$$

- Мы докажем, что α_i и d_i могут быть построены очень эффективно с вычислительной точки зрения (метод сопряженных градиентов).

Идея метода сопряженных направлений (CD)



Таким образом, мы формулируем алгоритм:

Предположим, что нам заранее известны линейно-независимые векторы u_0, \dots, u_{n-1} .

1. $d_0 = -\nabla f(x_0)$.

Идея метода сопряженных направлений (CD)



Таким образом, мы формулируем алгоритм:

Предположим, что нам заранее известны линейно-независимые векторы u_0, \dots, u_{n-1} .

1. $d_0 = -\nabla f(x_0)$.
2. С помощью процедуры точного линейного поиска находим оптимальную длину шага. Вычисляем α минимизируя $f(x_k + \alpha d_k)$ по формуле

$$\alpha_k = -\frac{d_k^\top (Ax_k - b)}{d_k^\top Ad_k} \quad (3)$$

Идея метода сопряженных направлений (CD)



Таким образом, мы формулируем алгоритм:

Предположим, что нам заранее известны линейно-независимые векторы u_0, \dots, u_{n-1} .

1. $d_0 = -\nabla f(x_0)$.
2. С помощью процедуры точного линейного поиска находим оптимальную длину шага. Вычисляем α минимизируя $f(x_k + \alpha_k d_k)$ по формуле

$$\alpha_k = -\frac{d_k^\top (Ax_k - b)}{d_k^\top A d_k} \quad (3)$$

3. Выполняем шаг алгоритма:

$$x_{k+1} = x_k + \alpha_k d_k$$

Идея метода сопряженных направлений (CD)



Таким образом, мы формулируем алгоритм:

Предположим, что нам заранее известны линейно-независимые векторы u_0, \dots, u_{n-1} .

1. $d_0 = -\nabla f(x_0)$.
2. С помощью процедуры точного линейного поиска находим оптимальную длину шага. Вычисляем α минимизируя $f(x_k + \alpha_k d_k)$ по формуле

$$\alpha_k = -\frac{d_k^\top (Ax_k - b)}{d_k^\top A d_k} \quad (3)$$

3. Выполняем шаг алгоритма:

$$x_{k+1} = x_k + \alpha_k d_k$$

4. Обновляем направление: d_{k+1} получаем из u_{k+1} с помощью модифицированной процедуры Грама–Шмидта в скалярном произведении $\langle v, w \rangle_A = v^\top A w$ относительно уже построенных d_0, \dots, d_k :

$$d_{k+1} = u_{k+1} - \sum_{i=0}^k \beta_{k+1,i} d_i, \quad \beta_{k+1,i} = \frac{u_{k+1}^\top A d_i}{d_i^\top A d_i}$$

что обеспечивает $d_{k+1} \perp_A d_j$ для всех $j \leq k$.

Идея метода сопряженных направлений (CD)



Таким образом, мы формулируем алгоритм:

Предположим, что нам заранее известны линейно-независимые векторы u_0, \dots, u_{n-1} .

1. $d_0 = -\nabla f(x_0)$.
2. С помощью процедуры точного линейного поиска находим оптимальную длину шага. Вычисляем α минимизируя $f(x_k + \alpha_k d_k)$ по формуле

$$\alpha_k = -\frac{d_k^\top (Ax_k - b)}{d_k^\top A d_k} \quad (3)$$

3. Выполняем шаг алгоритма:

$$x_{k+1} = x_k + \alpha_k d_k$$

4. Обновляем направление: d_{k+1} получаем из u_{k+1} с помощью модифицированной процедуры Грама–Шмидта в скалярном произведении $\langle v, w \rangle_A = v^\top A w$ относительно уже построенных d_0, \dots, d_k :

$$d_{k+1} = u_{k+1} - \sum_{i=0}^k \beta_{k+1,i} d_i, \quad \beta_{k+1,i} = \frac{u_{k+1}^\top A d_i}{d_i^\top A d_i}$$

что обеспечивает $d_{k+1} \perp_A d_j$ для всех $j \leq k$.

5. Повторяем шаги 2–4, пока не построим n направлений, где n — размерность пространства (x) .

Метод сопряженных направлений (CD)



i Лемма 1. Линейная независимость A -ортогональных векторов.

Если множество векторов d_1, \dots, d_n - попарно A -ортогональны (каждая пара векторов A -ортогональна), то эти векторы линейно независимы. $A \in \mathbb{S}_{++}^n$.

Метод сопряженных направлений (CD)



i Лемма 1. Линейная независимость A -ортогональных векторов.

Если множество векторов d_1, \dots, d_n - попарно A -ортогональны (каждая пара векторов A -ортогональна), то эти векторы линейно независимы. $A \in \mathbb{S}_{++}^n$.

Доказательство

Покажем, что если $\sum_{i=1}^n \alpha_i d_i = 0$, то все коэффициенты должны быть равны нулю:

Метод сопряженных направлений (CD)



i Лемма 1. Линейная независимость A -ортогональных векторов.

Если множество векторов d_1, \dots, d_n - попарно A -ортогональны (каждая пара векторов A -ортогональна), то эти векторы линейно независимы. $A \in \mathbb{S}_{++}^n$.

Доказательство

Покажем, что если $\sum_{i=1}^n \alpha_i d_i = 0$, то все коэффициенты должны быть равны нулю:

$$0 = \sum_{i=1}^n \alpha_i d_i$$

Метод сопряженных направлений (CD)



i Лемма 1. Линейная независимость A -ортогональных векторов.

Если множество векторов d_1, \dots, d_n - попарно A -ортогональны (каждая пара векторов A -ортогональна), то эти векторы линейно независимы. $A \in \mathbb{S}_{++}^n$.

Доказательство

Покажем, что если $\sum_{i=1}^n \alpha_i d_i = 0$, то все коэффициенты должны быть равны нулю:

$$\begin{aligned} 0 &= \sum_{i=1}^n \alpha_i d_i \\ (\text{Умножаем на } d_j^T A) \quad &= d_j^T A \left(\sum_{i=1}^n \alpha_i d_i \right) \end{aligned}$$

Метод сопряженных направлений (CD)



i Лемма 1. Линейная независимость A -ортогональных векторов.

Если множество векторов d_1, \dots, d_n - попарно A -ортогональны (каждая пара векторов A -ортогональна), то эти векторы линейно независимы. $A \in \mathbb{S}_{++}^n$.

Доказательство

Покажем, что если $\sum_{i=1}^n \alpha_i d_i = 0$, то все коэффициенты должны быть равны нулю:

$$\begin{aligned} 0 &= \sum_{i=1}^n \alpha_i d_i \\ (\text{Умножаем на } d_j^T A) \quad &= d_j^T A \left(\sum_{i=1}^n \alpha_i d_i \right) = \sum_{i=1}^n \alpha_i d_j^T A d_i \end{aligned}$$

Метод сопряженных направлений (CD)



i Лемма 1. Линейная независимость A -ортогональных векторов.

Если множество векторов d_1, \dots, d_n - попарно A -ортогональны (каждая пара векторов A -ортогональна), то эти векторы линейно независимы. $A \in \mathbb{S}_{++}^n$.

Доказательство

Покажем, что если $\sum_{i=1}^n \alpha_i d_i = 0$, то все коэффициенты должны быть равны нулю:

$$\begin{aligned} 0 &= \sum_{i=1}^n \alpha_i d_i \\ (\text{Умножаем на } d_j^T A) \quad &= d_j^T A \left(\sum_{i=1}^n \alpha_i d_i \right) = \sum_{i=1}^n \alpha_i d_j^T A d_i \\ &= \alpha_j d_j^T A d_j + 0 + \dots + 0 \end{aligned}$$

Метод сопряженных направлений (CD)



i Лемма 1. Линейная независимость A -ортогональных векторов.

Если множество векторов d_1, \dots, d_n - попарно A -ортогональны (каждая пара векторов A -ортогональна), то эти векторы линейно независимы. $A \in \mathbb{S}_{++}^n$.

Доказательство

Покажем, что если $\sum_{i=1}^n \alpha_i d_i = 0$, то все коэффициенты должны быть равны нулю:

$$\begin{aligned} 0 &= \sum_{i=1}^n \alpha_i d_i \\ (\text{Умножаем на } d_j^T A) \quad &= d_j^T A \left(\sum_{i=1}^n \alpha_i d_i \right) = \sum_{i=1}^n \alpha_i d_j^T A d_i \\ &= \alpha_j d_j^T A d_j + 0 + \dots + 0 \end{aligned}$$

Метод сопряженных направлений (CD)



i Лемма 1. Линейная независимость A -ортогональных векторов.

Если множество векторов d_1, \dots, d_n - попарно A -ортогональны (каждая пара векторов A -ортогональна), то эти векторы линейно независимы. $A \in \mathbb{S}_{++}^n$.

Доказательство

Покажем, что если $\sum_{i=1}^n \alpha_i d_i = 0$, то все коэффициенты должны быть равны нулю:

$$\begin{aligned} 0 &= \sum_{i=1}^n \alpha_i d_i \\ (\text{Умножаем на } d_j^T A) \quad &= d_j^T A \left(\sum_{i=1}^n \alpha_i d_i \right) = \sum_{i=1}^n \alpha_i d_j^T A d_i \\ &= \alpha_j d_j^T A d_j + 0 + \dots + 0 \end{aligned}$$

Таким образом, $\alpha_j = 0$, для всех остальных индексов нужно проделать тот же процесс

Доказательство сходимости



Введем следующие обозначения:

- $r_k = b - Ax_k$ - невязка

Доказательство сходимости



Введем следующие обозначения:

- $r_k = b - Ax_k$ - невязка
- $e_k = x_k - x^*$ - ошибка

Доказательство сходимости



Введем следующие обозначения:

- $r_k = b - Ax_k$ - невязка
- $e_k = x_k - x^*$ - ошибка
- Поскольку $Ax^* = b$, имеем $r_k = b - Ax_k = Ax^* - Ax_k = -A(x_k - x^*)$

$$r_k = -Ae_k. \quad (4)$$

Доказательство сходимости



Введем следующие обозначения:

- $r_k = b - Ax_k$ - невязка
- $e_k = x_k - x^*$ - ошибка
- Поскольку $Ax^* = b$, имеем $r_k = b - Ax_k = Ax^* - Ax_k = -A(x_k - x^*)$

$$r_k = -Ae_k. \quad (4)$$

- Также заметим, что поскольку $x_{k+1} = x_0 + \sum_{i=0}^k \alpha_i d_i$, имеем

$$e_{k+1} = e_0 + \sum_{i=0}^k \alpha_i d_i. \quad (5)$$

Доказательство сходимости



i Лемма 2. Сходимость метода сопряженных направлений.

Предположим, мы решаем n -мерную квадратичную сильно выпуклую задачу оптимизации (1). Метод сопряженных направлений

$$x_{k+1} = x_0 + \sum_{i=0}^k \alpha_i d_i$$

с $\alpha_i = \frac{\langle d_i, r_i \rangle}{\langle d_i, A d_i \rangle}$ взятым из точного линейного поиска, сходится за не более n шагов алгоритма.

Доказательство сходимости



i Лемма 2. Сходимость метода сопряженных направлений.

Предположим, мы решаем n -мерную квадратичную сильно выпуклую задачу оптимизации (1). Метод сопряженных направлений

$$x_{k+1} = x_0 + \sum_{i=0}^k \alpha_i d_i$$

с $\alpha_i = \frac{\langle d_i, r_i \rangle}{\langle d_i, A d_i \rangle}$ взятым из точного линейного поиска, сходится за не более n шагов алгоритма.

Доказательство Пусть

$$e_0 = x_0 - x^* = \sum_{i=0}^{n-1} \delta_i d_i$$

Докажем, что $\delta_i = -\alpha_i$:

Доказательство сходимости



i Лемма 2. Сходимость метода сопряженных направлений.

Предположим, мы решаем n -мерную квадратичную сильно выпуклую задачу оптимизации (1). Метод сопряженных направлений

$$x_{k+1} = x_0 + \sum_{i=0}^k \alpha_i d_i$$

с $\alpha_i = \frac{\langle d_i, r_i \rangle}{\langle d_i, A d_i \rangle}$ взятым из точного линейного поиска, сходится за не более n шагов алгоритма.

Доказательство Пусть

Умножаем обе части слева на $d_k^T A$:

$$e_0 = x_0 - x^* = \sum_{i=0}^{n-1} \delta_i d_i$$

$$d_k^T A e_0 = \sum_{i=0}^{n-1} \delta_i d_k^T A d_i$$

Докажем, что $\delta_i = -\alpha_i$:

Доказательство сходимости



i Лемма 2. Сходимость метода сопряженных направлений.

Предположим, мы решаем n -мерную квадратичную сильно выпуклую задачу оптимизации (1). Метод сопряженных направлений

$$x_{k+1} = x_0 + \sum_{i=0}^k \alpha_i d_i$$

с $\alpha_i = \frac{\langle d_i, r_i \rangle}{\langle d_i, A d_i \rangle}$ взятым из точного линейного поиска, сходится за не более n шагов алгоритма.

Доказательство Пусть

Умножаем обе части слева на $d_k^T A$:

$$e_0 = x_0 - x^* = \sum_{i=0}^{n-1} \delta_i d_i$$

$$d_k^T A e_0 = \sum_{i=0}^{n-1} \delta_i d_k^T A d_i = \delta_k d_k^T A d_k$$

Докажем, что $\delta_i = -\alpha_i$:

Доказательство сходимости



i Лемма 2. Сходимость метода сопряженных направлений.

Предположим, мы решаем n -мерную квадратичную сильно выпуклую задачу оптимизации (1). Метод сопряженных направлений

$$x_{k+1} = x_0 + \sum_{i=0}^k \alpha_i d_i$$

с $\alpha_i = \frac{\langle d_i, r_i \rangle}{\langle d_i, A d_i \rangle}$ взятым из точного линейного поиска, сходится за не более n шагов алгоритма.

Доказательство Пусть

Умножаем обе части слева на $d_k^T A$:

$$e_0 = x_0 - x^* = \sum_{i=0}^{n-1} \delta_i d_i$$

$$d_k^T A e_0 = \sum_{i=0}^{n-1} \delta_i d_k^T A d_i = \delta_k d_k^T A d_k$$

Докажем, что $\delta_i = -\alpha_i$:

$$d_k^T A e_k$$

Доказательство сходимости



i Лемма 2. Сходимость метода сопряженных направлений.

Предположим, мы решаем n -мерную квадратичную сильно выпуклую задачу оптимизации (1). Метод сопряженных направлений

$$x_{k+1} = x_0 + \sum_{i=0}^k \alpha_i d_i$$

с $\alpha_i = \frac{\langle d_i, r_i \rangle}{\langle d_i, A d_i \rangle}$ взятым из точного линейного поиска, сходится за не более n шагов алгоритма.

Доказательство Пусть

Умножаем обе части слева на $d_k^T A$:

$$e_0 = x_0 - x^* = \sum_{i=0}^{n-1} \delta_i d_i$$

$$d_k^T A e_0 = \sum_{i=0}^{n-1} \delta_i d_k^T A d_i = \delta_k d_k^T A d_k$$

Докажем, что $\delta_i = -\alpha_i$:

$$d_k^T A e_k = d_k^T A \left(e_0 + \sum_{i=0}^{k-1} \alpha_i d_i \right)$$

Доказательство сходимости



i Лемма 2. Сходимость метода сопряженных направлений.

Предположим, мы решаем n -мерную квадратичную сильно выпуклую задачу оптимизации (1). Метод сопряженных направлений

$$x_{k+1} = x_0 + \sum_{i=0}^k \alpha_i d_i$$

с $\alpha_i = \frac{\langle d_i, r_i \rangle}{\langle d_i, A d_i \rangle}$ взятым из точного линейного поиска, сходится за не более n шагов алгоритма.

Доказательство Пусть

Умножаем обе части слева на $d_k^T A$:

$$e_0 = x_0 - x^* = \sum_{i=0}^{n-1} \delta_i d_i$$

$$d_k^T A e_0 = \sum_{i=0}^{n-1} \delta_i d_k^T A d_i = \delta_k d_k^T A d_k$$

Докажем, что $\delta_i = -\alpha_i$:

$$d_k^T A e_k = d_k^T A \left(e_0 + \sum_{i=0}^{k-1} \alpha_i d_i \right) \stackrel{\perp_A}{=} \delta_k d_k^T A d_k$$

Доказательство сходимости



i Лемма 2. Сходимость метода сопряженных направлений.

Предположим, мы решаем n -мерную квадратичную сильно выпуклую задачу оптимизации (1). Метод сопряженных направлений

$$x_{k+1} = x_0 + \sum_{i=0}^k \alpha_i d_i$$

с $\alpha_i = \frac{\langle d_i, r_i \rangle}{\langle d_i, A d_i \rangle}$ взятым из точного линейного поиска, сходится за не более n шагов алгоритма.

Доказательство Пусть

Умножаем обе части слева на $d_k^T A$:

$$e_0 = x_0 - x^* = \sum_{i=0}^{n-1} \delta_i d_i$$

Докажем, что $\delta_i = -\alpha_i$:

$$d_k^T A e_0 = \sum_{i=0}^{n-1} \delta_i d_k^T A d_i = \delta_k d_k^T A d_k$$

$$d_k^T A e_k = d_k^T A \left(e_0 + \sum_{i=0}^{k-1} \alpha_i d_i \right) \stackrel{\perp_A}{=} \delta_k d_k^T A d_k$$

$$\delta_k = \frac{d_k^T A e_k}{d_k^T A d_k}$$

Доказательство сходимости



i Лемма 2. Сходимость метода сопряженных направлений.

Предположим, мы решаем n -мерную квадратичную сильно выпуклую задачу оптимизации (1). Метод сопряженных направлений

$$x_{k+1} = x_0 + \sum_{i=0}^k \alpha_i d_i$$

с $\alpha_i = \frac{\langle d_i, r_i \rangle}{\langle d_i, A d_i \rangle}$ взятым из точного линейного поиска, сходится за не более n шагов алгоритма.

Доказательство Пусть

Умножаем обе части слева на $d_k^T A$:

$$e_0 = x_0 - x^* = \sum_{i=0}^{n-1} \delta_i d_i$$

Докажем, что $\delta_i = -\alpha_i$:

$$d_k^T A e_0 = \sum_{i=0}^{n-1} \delta_i d_k^T A d_i = \delta_k d_k^T A d_k$$

$$d_k^T A e_k = d_k^T A \left(e_0 + \sum_{i=0}^{k-1} \alpha_i d_i \right) \stackrel{\perp_A}{=} \delta_k d_k^T A d_k$$

$$\delta_k = \frac{d_k^T A e_k}{d_k^T A d_k} = -\frac{d_k^T r_k}{d_k^T A d_k}$$

Доказательство сходимости



i Лемма 2. Сходимость метода сопряженных направлений.

Предположим, мы решаем n -мерную квадратичную сильно выпуклую задачу оптимизации (1). Метод сопряженных направлений

$$x_{k+1} = x_0 + \sum_{i=0}^k \alpha_i d_i$$

с $\alpha_i = \frac{\langle d_i, r_i \rangle}{\langle d_i, A d_i \rangle}$ взятым из точного линейного поиска, сходится за не более n шагов алгоритма.

Доказательство Пусть

Умножаем обе части слева на $d_k^T A$:

$$e_0 = x_0 - x^* = \sum_{i=0}^{n-1} \delta_i d_i$$

Докажем, что $\delta_i = -\alpha_i$:

$$d_k^T A e_0 = \sum_{i=0}^{n-1} \delta_i d_k^T A d_i = \delta_k d_k^T A d_k$$

$$d_k^T A e_k = d_k^T A \left(e_0 + \sum_{i=0}^{k-1} \alpha_i d_i \right) \stackrel{\perp_A}{=} \delta_k d_k^T A d_k$$

$$\delta_k = \frac{d_k^T A e_k}{d_k^T A d_k} = -\frac{d_k^T r_k}{d_k^T A d_k} \Leftrightarrow \delta_k = -\alpha_k$$

Метод сопряженных градиентов (CG)

Идея метода сопряженных градиентов (CG)



- Это буквально метод сопряженных направлений, в котором мы выбираем специальный набор d_0, \dots, d_{n-1} , позволяющий значительно ускорить процесс Грама-Шмидта.

Идея метода сопряженных градиентов (CG)



- Это буквально метод сопряженных направлений, в котором мы выбираем специальный набор d_0, \dots, d_{n-1} , позволяющий значительно ускорить процесс Грама-Шмидта.
- Используется процесс Грама-Шмидта с A -ортогональностью вместо Евклидовой ортогональности, чтобы получить их из набора начальных векторов.

Идея метода сопряженных градиентов (CG)



- Это буквально метод сопряженных направлений, в котором мы выбираем специальный набор d_0, \dots, d_{n-1} , позволяющий значительно ускорить процесс Грама-Шмидта.
- Используется процесс Грама-Шмидта с A -ортогональностью вместо Евклидовой ортогональности, чтобы получить их из набора начальных векторов.
- На каждой итерации r_0, \dots, r_{n-1} используются в качестве начальных линейно-независимых векторов для процесса Грама-Шмидта.

Идея метода сопряженных градиентов (CG)



- Это буквально метод сопряженных направлений, в котором мы выбираем специальный набор d_0, \dots, d_{n-1} , позволяющий значительно ускорить процесс Грама-Шмидта.
- Используется процесс Грама-Шмидта с A -ортогональностью вместо Евклидовой ортогональности, чтобы получить их из набора начальных векторов.
- На каждой итерации r_0, \dots, r_{n-1} используются в качестве начальных линейно-независимых векторов для процесса Грама-Шмидта.
- Основная идея заключается в том, что для произвольного метода CD процесс Грама-Шмидта вычислительно дорогой и требует квадратичного числа операций сложения векторов и скалярных произведений $\mathcal{O}(n^2)$, в то время как в случае CG мы покажем, что сложность этой процедуры может быть уменьшена до линейной $\mathcal{O}(n)$.

Идея метода сопряженных градиентов (CG)



- Это буквально метод сопряженных направлений, в котором мы выбираем специальный набор d_0, \dots, d_{n-1} , позволяющий значительно ускорить процесс Грама-Шмидта.
- Используется процесс Грама-Шмидта с A -ортогональностью вместо Евклидовой ортогональности, чтобы получить их из набора начальных векторов.
- На каждой итерации r_0, \dots, r_{n-1} используются в качестве начальных линейно-независимых векторов для процесса Грама-Шмидта.
- Основная идея заключается в том, что для произвольного метода CD процесс Грама-Шмидта вычислительно дорогой и требует квадратичного числа операций сложения векторов и скалярных произведений $\mathcal{O}(n^2)$, в то время как в случае CG мы покажем, что сложность этой процедуры может быть уменьшена до линейной $\mathcal{O}(n)$.

Идея метода сопряженных градиентов (CG)

- Это буквально метод сопряженных направлений, в котором мы выбираем специальный набор d_0, \dots, d_{n-1} , позволяющий значительно ускорить процесс Грама-Шмидта.
- Используется процесс Грама-Шмидта с A -ортогональностью вместо Евклидовой ортогональности, чтобы получить их из набора начальных векторов.
- На каждой итерации r_0, \dots, r_{n-1} используются в качестве начальных линейно-независимых векторов для процесса Грама-Шмидта.
- Основная идея заключается в том, что для произвольного метода CD процесс Грама-Шмидта вычислительно дорогой и требует квадратичного числа операций сложения векторов и скалярных произведений $\mathcal{O}(n^2)$, в то время как в случае CG мы покажем, что сложность этой процедуры может быть уменьшена до линейной $\mathcal{O}(n)$.



CG = CD + r_0, \dots, r_{n-1} как начальные векторы для процесса Грама-Шмидта + A -ортогональность.

Леммы для сходимости



i Лемма 5. Невязки ортогональны друг другу в методе CG

Все невязки в методе CG ортогональны друг другу:

$$r_i^T r_k = 0 \quad \forall i \neq k \quad (6)$$

i Лемма 7. Коэффициенты для процесса Грама-Шмидта для CG

В процессе Грама-Шмидта для CG

$$\beta_{ji} = \frac{r_i^T r_i}{r_{i-1}^T r_{i-1}}, \quad i = j + 1.$$

Все остальные коэффициенты равны нулю кроме $i = j$, но этот случай нам неинтересен.

Метод сопряженных градиентов (CG)



$$r_0 := b - Ax_0$$

if r_0 is sufficiently small, then return x_0 as the result

$$d_0 := r_0$$

$$k := 0$$

repeat

$$\alpha_k := \frac{r_k^\top r_k}{d_k^\top A d_k}$$

$$x_{k+1} := x_k + \alpha_k d_k$$

$$r_{k+1} := r_k - \alpha_k A d_k$$

if r_{k+1} is sufficiently small, then exit loop

$$\beta_k := \frac{r_{k+1}^\top r_{k+1}}{r_k^\top r_k}$$



$$d_{k+1} := r_{k+1} + \beta_k d_k$$

$$k := k + 1$$

end repeat

return x_{k+1} as the result

Закрываем квадратичный вопрос



Сходимость



Теорема 1. Если матрица A имеет только r различных собственных значений, то метод сопряженных градиентов сходится за r итераций.

Теорема 2. Следующая оценка сходимости выполняется для метода сопряженных градиентов, как для итерационного метода в сильно выпуклой задаче:

$$\|x_k - x^*\|_A \leq 2 \left(\frac{\sqrt{\kappa(A)} - 1}{\sqrt{\kappa(A)} + 1} \right)^k \|x_0 - x^*\|_A,$$

где $\|x\|_A^2 = x^\top A x$ и $\kappa(A) = \frac{\lambda_1(A)}{\lambda_n(A)}$ - это число обусловленности матрицы A , $\lambda_1(A) \geq \dots \geq \lambda_n(A)$ - собственные значения матрицы A


Примечание: Сравните коэффициент геометрической прогрессии с его аналогом в методе градиентного спуска.

Численные эксперименты



$$f(x) = \frac{1}{2}x^T A x - b^T x \rightarrow \min_{x \in \mathbb{R}^n}$$

Convex quadratics. $n=60$, random matrix.




Численные эксперименты



$$f(x) = \frac{1}{2}x^T A x - b^T x \rightarrow \min_{x \in \mathbb{R}^n}$$

Strongly convex quadratics. $n=60$, random matrix.




Численные эксперименты



$$f(x) = \frac{1}{2}x^T A x - b^T x \rightarrow \min_{x \in \mathbb{R}^n}$$

Strongly convex quadratics. $n=60$, random matrix.




Численные эксперименты



$$f(x) = \frac{1}{2}x^T A x - b^T x \rightarrow \min_{x \in \mathbb{R}^n}$$

Strongly convex quadratics. $n=60$, clustered matrix.




Численные эксперименты



$$f(x) = \frac{1}{2}x^T A x - b^T x \rightarrow \min_{x \in \mathbb{R}^n}$$

Strongly convex quadratics. $n=600$, clustered matrix.




Численные эксперименты



$$f(x) = \frac{1}{2}x^T A x - b^T x \rightarrow \min_{x \in \mathbb{R}^n}$$

Strongly convex quadratics. $n=60$, uniform spectrum matrix.




Численные эксперименты



$$f(x) = \frac{1}{2}x^T A x - b^T x \rightarrow \min_{x \in \mathbb{R}^n}$$

Strongly convex quadratics. $n=60$, Hilbert matrix.



Численные эксперименты



Здесь должны быть видосы, но у меня не получилось их вставить, так что покажу через VSCode.

Метод сопряженных градиентов для неквадратичных задач (Non-linear CG)

Метод сопряженных градиентов для неквадратичных задач (Non-linear CG)



В случае, когда нет аналитического выражения для функции или ее градиента, мы, скорее всего, не сможем решить одномерную задачу минимизации аналитически. Поэтому α_k подбирается обычной процедурой линейного поиска. Но для выбора β_k есть следующий математический трюк:

Для двух итераций справедливо:

$$x_{k+1} - x_k = cd_k,$$

Метод сопряженных градиентов для неквадратичных задач (Non-linear CG)



В случае, когда нет аналитического выражения для функции или ее градиента, мы, скорее всего, не сможем решить одномерную задачу минимизации аналитически. Поэтому α_k подбирается обычной процедурой линейного поиска. Но для выбора β_k есть следующий математический трюк:

Для двух итераций справедливо:

$$x_{k+1} - x_k = cd_k,$$

где c - некоторая константа. Тогда для квадратичного случая мы имеем:

$$\nabla f(x_{k+1}) - \nabla f(x_k) = (Ax_{k+1} - b) - (Ax_k - b) = A(x_{k+1} - x_k) = cAd_k$$

Метод сопряженных градиентов для неквадратичных задач (Non-linear CG)



В случае, когда нет аналитического выражения для функции или ее градиента, мы, скорее всего, не сможем решить одномерную задачу минимизации аналитически. Поэтому α_k подбирается обычной процедурой линейного поиска. Но для выбора β_k есть следующий математический трюк:

Для двух итераций справедливо:

$$x_{k+1} - x_k = c d_k,$$

где c - некоторая константа. Тогда для квадратичного случая мы имеем:

$$\nabla f(x_{k+1}) - \nabla f(x_k) = (Ax_{k+1} - b) - (Ax_k - b) = A(x_{k+1} - x_k) = cAd_k$$

Выражая из этого уравнения величину $Ad_k = \frac{1}{c} (\nabla f(x_{k+1}) - \nabla f(x_k))$, мы избавляемся от знания функции в определении β_k , тогда пункт 4 будет переписан как:

$$\beta_k = \frac{\nabla f(x_{k+1})^\top (\nabla f(x_{k+1}) - \nabla f(x_k))}{d_k^\top (\nabla f(x_{k+1}) - \nabla f(x_k))}.$$



Этот метод называется методом Полака-Рибьера.

Численные эксперименты



$$f(x) = \frac{\mu}{2} \|x\|_2^2 + \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-y_i \langle a_i, x \rangle)) \rightarrow \min_{x \in \mathbb{R}^n}$$

Regularized binary logistic regression. $n=300$. $m=1000$. $\mu=0$





Численные эксперименты



$$f(x) = \frac{\mu}{2} \|x\|_2^2 + \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-y_i \langle a_i, x \rangle)) \rightarrow \min_{x \in \mathbb{R}^n}$$

Regularized binary logistic regression. $n=300$. $m=1000$. $\mu=1$






Численные эксперименты



$$f(x) = \frac{\mu}{2} \|x\|_2^2 + \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-y_i \langle a_i, x \rangle)) \rightarrow \min_{x \in \mathbb{R}^n}$$

Regularized binary logistic regression. $n=300$. $m=1000$. $\mu=1$






Численные эксперименты



$$f(x) = \frac{\mu}{2} \|x\|_2^2 + \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-y_i \langle a_i, x \rangle)) \rightarrow \min_{x \in \mathbb{R}^n}$$

Regularized binary logistic regression. $n=300$. $m=1000$. $\mu=1$





Численные эксперименты



$$f(x) = \frac{\mu}{2} \|x\|_2^2 + \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-y_i \langle a_i, x \rangle)) \rightarrow \min_{x \in \mathbb{R}^n}$$

Regularized binary logistic regression. $n=300$. $m=1000$. $\mu=10$






— Gradient Descent -.- Steepest Descent - - - Conjugate Gradients PR - - - Conjugate Gradients FR

Численные эксперименты



$$f(x) = \frac{\mu}{2} \|x\|_2^2 + \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-y_i \langle a_i, x \rangle)) \rightarrow \min_{x \in \mathbb{R}^n}$$

Regularized binary logistic regression. $n=300$. $m=1000$. $\mu=10$



Бонус: дополнительные технические леммы и доказательства

Леммы для сходимости



i Лемма 3. Разложение ошибки.

$$e_i = \sum_{j=i}^{n-1} -\alpha_j d_j \quad (7)$$

Леммы для сходимости



i Лемма 3. Разложение ошибки.

$$e_i = \sum_{j=i}^{n-1} -\alpha_j d_j \quad (7)$$

Доказательство

По определению

$$e_i = e_0 + \sum_{j=0}^{i-1} \alpha_j d_j$$

Леммы для сходимости



i Лемма 3. Разложение ошибки.

$$e_i = \sum_{j=i}^{n-1} -\alpha_j d_j \quad (7)$$

Доказательство

По определению

$$e_i = e_0 + \sum_{j=0}^{i-1} \alpha_j d_j = x_0 - x^* + \sum_{j=0}^{i-1} \alpha_j d_j$$

Леммы для сходимости



i Лемма 3. Разложение ошибки.

$$e_i = \sum_{j=i}^{n-1} -\alpha_j d_j \quad (7)$$

Доказательство

По определению

$$e_i = e_0 + \sum_{j=0}^{i-1} \alpha_j d_j = x_0 - x^* + \sum_{j=0}^{i-1} \alpha_j d_j = - \sum_{j=0}^{n-1} \alpha_j d_j + \sum_{j=0}^{i-1} \alpha_j d_j$$

Леммы для сходимости



i Лемма 3. Разложение ошибки.

$$e_i = \sum_{j=i}^{n-1} -\alpha_j d_j \quad (7)$$

Доказательство

По определению

$$e_i = e_0 + \sum_{j=0}^{i-1} \alpha_j d_j = x_0 - x^* + \sum_{j=0}^{i-1} \alpha_j d_j = - \sum_{j=0}^{n-1} \alpha_j d_j + \sum_{j=0}^{i-1} \alpha_j d_j = \sum_{j=i}^{n-1} -\alpha_j d_j$$

Леммы для сходимости



i Лемма 4. Невязка ортогональна всем предыдущим направлениям для CD.

Рассмотрим невязку метода сопряженных направлений на k итерации r_k , тогда для любого $i < k$:

$$d_i^T r_k = 0 \tag{8}$$

Леммы для сходимости



i Лемма 4. Невязка ортогональна всем предыдущим направлениям для CD.

Рассмотрим невязку метода сопряженных направлений на k итерации r_k , тогда для любого $i < k$:

$$d_i^T r_k = 0 \tag{8}$$

Доказательство

Запишем (7) для некоторого фиксированного индекса k :

Леммы для сходимости



i Лемма 4. Невязка ортогональна всем предыдущим направлениям для CD.

Рассмотрим невязку метода сопряженных направлений на k итерации r_k , тогда для любого $i < k$:

$$d_i^T r_k = 0 \quad (8)$$

Доказательство

Запишем (7) для некоторого фиксированного индекса k :

$$e_k = \sum_{j=k}^{n-1} -\alpha_j d_j$$

Леммы для сходимости



i Лемма 4. Невязка ортогональна всем предыдущим направлениям для CD.

Рассмотрим невязку метода сопряженных направлений на k итерации r_k , тогда для любого $i < k$:

$$d_i^T r_k = 0 \quad (8)$$


Доказательство

Запишем (7) для некоторого фиксированного индекса k :

$$e_k = \sum_{j=k}^{n-1} -\alpha_j d_j$$

Умножаем обе части на $-d_i^T A$.

$$-d_i^T A e_k = \sum_{j=k}^{n-1} \alpha_j d_i^T A d_j = 0$$



образом, $d_i^T r_k = 0$ и невязка r_k ортогональна всем предыдущим направлениям d_i для метода CD.

Таким

Леммы для сходимости



i Лемма 5. Невязки ортогональны друг другу в методе CG

Все невязки в методе CG ортогональны друг другу:

$$r_i^T r_k = 0 \quad \forall i \neq k \quad (9)$$

Леммы для сходимости



i Лемма 5. Невязки ортогональны друг другу в методе CG

Все невязки в методе CG ортогональны друг другу:

$$r_i^T r_k = 0 \quad \forall i \neq k \quad (9)$$

Доказательство

Запишем процесс Грама-Шмидта (2) с $\langle \cdot, \cdot \rangle$

замененным на $\langle \cdot, \cdot \rangle_A = x^T A y$

Леммы для сходимости



i Лемма 5. Невязки ортогональны друг другу в методе CG

Все невязки в методе CG ортогональны друг другу:

$$r_i^T r_k = 0 \quad \forall i \neq k \quad (9)$$

Доказательство

Запишем процесс Грама-Шмидта (2) с $\langle \cdot, \cdot \rangle$

замененным на $\langle \cdot, \cdot \rangle_A = x^T A y$

$$d_i = u_i + \sum_{j=0}^{i-1} \beta_{ji} d_j \quad \beta_{ji} = -\frac{\langle d_j, u_i \rangle_A}{\langle d_j, d_j \rangle_A} \quad (10)$$

Леммы для сходимости



i Лемма 5. Невязки ортогональны друг другу в методе CG

Все невязки в методе CG ортогональны друг другу:

$$r_i^T r_k = 0 \quad \forall i \neq k \quad (9)$$

Доказательство

Запишем процесс Грама-Шмидта (2) с $\langle \cdot, \cdot \rangle$
замененным на $\langle \cdot, \cdot \rangle_A = x^T A y$

$$d_i = u_i + \sum_{j=0}^{i-1} \beta_{ji} d_j \quad \beta_{ji} = -\frac{\langle d_j, u_i \rangle_A}{\langle d_j, d_j \rangle_A} \quad (10)$$

Тогда, мы используем невязки в качестве
начальных векторов для процесса и $u_i = r_i$.

Леммы для сходимости



i Лемма 5. Невязки ортогональны друг другу в методе CG

Все невязки в методе CG ортогональны друг другу:

$$r_i^T r_k = 0 \quad \forall i \neq k \quad (9)$$


Доказательство

Запишем процесс Грама-Шмидта (2) с $\langle \cdot, \cdot \rangle$
замененным на $\langle \cdot, \cdot \rangle_A = x^T A y$

$$d_i = u_i + \sum_{j=0}^{i-1} \beta_{ji} d_j \quad \beta_{ji} = -\frac{\langle d_j, u_i \rangle_A}{\langle d_j, d_j \rangle_A} \quad (10)$$

Тогда, мы используем невязки в качестве
начальных векторов для процесса и $u_i = r_i$.

$$d_i = r_i + \sum_{j=0}^{i-1} \beta_{ji} d_j \quad \beta_{ji} = -\frac{\langle d_j, r_i \rangle_A}{\langle d_j, d_j \rangle_A} \quad (11)$$



Умножаем обе части (10) на r_k^T для некоторого индекса k :

$$r_k^T d_i = r_k^T u_i + \sum_{j=0}^{i-1} \beta_{ji} r_k^T d_j$$

Леммы для сходимости



i Лемма 5. Невязки ортогональны друг другу в методе CG

Все невязки в методе CG ортогональны друг другу:

$$r_i^T r_k = 0 \quad \forall i \neq k \quad (9)$$


Доказательство

Запишем процесс Грама-Шмидта (2) с $\langle \cdot, \cdot \rangle$ замененным на $\langle \cdot, \cdot \rangle_A = x^T A y$

$$d_i = u_i + \sum_{j=0}^{i-1} \beta_{ji} d_j \quad \beta_{ji} = -\frac{\langle d_j, u_i \rangle_A}{\langle d_j, d_j \rangle_A} \quad (10)$$

Тогда, мы используем невязки в качестве начальных векторов для процесса и $u_i = r_i$.

$$d_i = r_i + \sum_{j=0}^{i-1} \beta_{ji} d_j \quad \beta_{ji} = -\frac{\langle d_j, r_i \rangle_A}{\langle d_j, d_j \rangle_A} \quad (11)$$



Умножаем обе части (10) на r_k^T для некоторого индекса k :

$$r_k^T d_i = r_k^T u_i + \sum_{j=0}^{i-1} \beta_{ji} r_k^T d_j$$

Если $j < i < k$, то имеем лемму 4 с $d_i^T r_k = 0$ и $d_j^T r_k = 0$. Имеем:

$$r_k^T u_i = 0 \quad \text{для CD} \quad r_k^T r_i = 0 \quad \text{для CG}$$

Леммы для сходимости



Более того, если $k = i$:

$$r_k^T d_k = r_k^T u_k + \sum_{j=0}^{k-1} \beta_{jk} r_k^T d_j$$

Леммы для сходимости



Более того, если $k = i$:

$$r_k^T d_k = r_k^T u_k + \sum_{j=0}^{k-1} \beta_{jk} r_k^T d_j = r_k^T u_k + 0,$$

Леммы для сходимости



Более того, если $k = i$:

$$r_k^T d_k = r_k^T u_k + \sum_{j=0}^{k-1} \beta_{jk} r_k^T d_j = r_k^T u_k + 0,$$

Леммы для сходимости



Более того, если $k = i$:

$$r_k^T d_k = r_k^T u_k + \sum_{j=0}^{k-1} \beta_{jk} r_k^T d_j = r_k^T u_k + 0,$$

и мы имеем для любого k (из-за произвольного выбора i):

$$r_k^T d_k = r_k^T u_k. \tag{12}$$

Леммы для сходимости



Более того, если $k = i$:

$$r_k^T d_k = r_k^T u_k + \sum_{j=0}^{k-1} \beta_{jk} r_k^T d_j = r_k^T u_k + 0,$$

и мы имеем для любого k (из-за произвольного выбора i):

$$r_k^T d_k = r_k^T u_k. \tag{12}$$

Леммы для сходимости



i Лемма 6. Пересчет невязки

$$r_{k+1} = r_k - \alpha_k A d_k \quad (13)$$

Леммы для сходимости



i Лемма 6. Пересчет невязки

$$r_{k+1} = r_k - \alpha_k A d_k \quad (13)$$

$$r_{k+1} = -A e_{k+1} = -A(e_k + \alpha_k d_k) = -A e_k - \alpha_k A d_k = r_k - \alpha_k A d_k$$

Наконец, все эти вышеуказанные леммы достаточны для доказательства, что $\beta_{ji} = 0$ для всех i, j , кроме соседних.

Леммы для сходимости



i Лемма 7. Коэффициенты для процесса Грама-Шмидта для CG

В процессе Грама-Шмидта для CG

$$\beta_{ji} = \frac{\langle r_i, r_i \rangle}{r_{i-1}, r_{i-1}}, \quad i = j + 1.$$

Все остальные коэффициенты равны нулю кроме $i = j$, но этот случай нам неинтересен.

Рассмотрим процесс Грам-Шмидта в методе CG

$$\beta_{ji} = -\frac{\langle d_j, u_i \rangle_A}{\langle d_j, d_j \rangle_A}$$

Леммы для сходимости



i Лемма 7. Коэффициенты для процесса Грама-Шмидта для CG

В процессе Грама-Шмидта для CG

$$\beta_{ji} = \frac{\langle r_i, r_i \rangle}{r_{i-1}, r_{i-1}}, \quad i = j + 1.$$

Все остальные коэффициенты равны нулю кроме $i = j$, но этот случай нам неинтересен.

Рассмотрим процесс Грам-Шмидта в методе CG

$$\beta_{ji} = -\frac{\langle d_j, u_i \rangle_A}{\langle d_j, d_j \rangle_A} = -\frac{d_j^T A u_i}{d_j^T A d_j}$$

Леммы для сходимости



i Лемма 7. Коэффициенты для процесса Грама-Шмидта для CG

В процессе Грама-Шмидта для CG

$$\beta_{ji} = \frac{\langle r_i, r_i \rangle}{r_{i-1}, r_{i-1}}, \quad i = j + 1.$$

Все остальные коэффициенты равны нулю кроме $i = j$, но этот случай нам неинтересен.

Рассмотрим процесс Грам-Шмидта в методе CG

$$\beta_{ji} = -\frac{\langle d_j, u_i \rangle_A}{\langle d_j, d_j \rangle_A} = -\frac{d_j^T A u_i}{d_j^T A d_j} = -\frac{d_j^T A r_i}{d_j^T A d_j}$$

Леммы для сходимости



i Лемма 7. Коэффициенты для процесса Грама-Шмидта для CG

В процессе Грама-Шмидта для CG

$$\beta_{ji} = \frac{\langle r_i, r_i \rangle}{r_{i-1}, r_{i-1}}, \quad i = j + 1.$$

Все остальные коэффициенты равны нулю кроме $i = j$, но этот случай нам неинтересен.

Рассмотрим процесс Грам-Шмидта в методе CG

$$\beta_{ji} = -\frac{\langle d_j, u_i \rangle_A}{\langle d_j, d_j \rangle_A} = -\frac{d_j^T A u_i}{d_j^T A d_j} = -\frac{d_j^T A r_i}{d_j^T A d_j} = -\frac{r_i^T A d_j}{d_j^T A d_j}.$$

Леммы для сходимости



i Лемма 7. Коэффициенты для процесса Грама-Шмидта для CG

В процессе Грама-Шмидта для CG

$$\beta_{ji} = \frac{\langle r_i, r_i \rangle}{r_{i-1}, r_{i-1}}, \quad i = j + 1.$$

Все остальные коэффициенты равны нулю кроме $i = j$, но этот случай нам неинтересен.

Рассмотрим процесс Грам-Шмидта в методе CG

$$\beta_{ji} = -\frac{\langle d_j, u_i \rangle_A}{\langle d_j, d_j \rangle_A} = -\frac{d_j^T A u_i}{d_j^T A d_j} = -\frac{d_j^T A r_i}{d_j^T A d_j} = -\frac{r_i^T A d_j}{d_j^T A d_j}.$$

Леммы для сходимости



i Лемма 7. Коэффициенты для процесса Грама-Шмидта для CG

В процессе Грама-Шмидта для CG

$$\beta_{ji} = \frac{\langle r_i, r_i \rangle}{r_{i-1}, r_{i-1}}, \quad i = j + 1.$$

Все остальные коэффициенты равны нулю кроме $i = j$, но этот случай нам неинтересен.

Рассмотрим процесс Грам-Шмидта в методе CG

$$\beta_{ji} = -\frac{\langle d_j, u_i \rangle_A}{\langle d_j, d_j \rangle_A} = -\frac{d_j^T A u_i}{d_j^T A d_j} = -\frac{d_j^T A r_i}{d_j^T A d_j} = -\frac{r_i^T A d_j}{d_j^T A d_j}.$$

Рассмотрим скалярное произведение $\langle r_i, r_{j+1} \rangle$ используя (13):

$$\langle r_i, r_{j+1} \rangle$$

Леммы для сходимости



i Лемма 7. Коэффициенты для процесса Грама-Шмидта для CG

В процессе Грама-Шмидта для CG

$$\beta_{ji} = \frac{\langle r_i, r_i \rangle}{r_{i-1}, r_{i-1}}, \quad i = j + 1.$$

Все остальные коэффициенты равны нулю кроме $i = j$, но этот случай нам неинтересен.

Рассмотрим процесс Грам-Шмидта в методе CG

$$\beta_{ji} = -\frac{\langle d_j, u_i \rangle_A}{\langle d_j, d_j \rangle_A} = -\frac{d_j^T A u_i}{d_j^T A d_j} = -\frac{d_j^T A r_i}{d_j^T A d_j} = -\frac{r_i^T A d_j}{d_j^T A d_j}.$$

Рассмотрим скалярное произведение $\langle r_i, r_{j+1} \rangle$ используя (13):

$$\langle r_i, r_{j+1} \rangle = \langle r_i, r_j - \alpha_j A d_j \rangle$$

Леммы для сходимости



i Лемма 7. Коэффициенты для процесса Грама-Шмидта для CG

В процессе Грама-Шмидта для CG

$$\beta_{ji} = \frac{\langle r_i, r_i \rangle}{r_{i-1}, r_{i-1}}, \quad i = j + 1.$$

Все остальные коэффициенты равны нулю кроме $i = j$, но этот случай нам неинтересен.

Рассмотрим процесс Грам-Шмидта в методе CG

$$\beta_{ji} = -\frac{\langle d_j, u_i \rangle_A}{\langle d_j, d_j \rangle_A} = -\frac{d_j^T A u_i}{d_j^T A d_j} = -\frac{d_j^T A r_i}{d_j^T A d_j} = -\frac{r_i^T A d_j}{d_j^T A d_j}.$$

Рассмотрим скалярное произведение $\langle r_i, r_{j+1} \rangle$ используя (13):

$$\langle r_i, r_{j+1} \rangle = \langle r_i, r_j - \alpha_j A d_j \rangle = \langle r_i, r_j \rangle - \alpha_j \langle r_i, A d_j \rangle$$

Леммы для сходимости



i Лемма 7. Коэффициенты для процесса Грама-Шмидта для CG

В процессе Грама-Шмидта для CG

$$\beta_{ji} = \frac{\langle r_i, r_i \rangle}{r_{i-1}, r_{i-1}}, \quad i = j + 1.$$

Все остальные коэффициенты равны нулю кроме $i = j$, но этот случай нам неинтересен.

Рассмотрим процесс Грам-Шмидта в методе CG

$$\beta_{ji} = -\frac{\langle d_j, u_i \rangle_A}{\langle d_j, d_j \rangle_A} = -\frac{d_j^T A u_i}{d_j^T A d_j} = -\frac{d_j^T A r_i}{d_j^T A d_j} = -\frac{r_i^T A d_j}{d_j^T A d_j}.$$

Рассмотрим скалярное произведение $\langle r_i, r_{j+1} \rangle$ используя (13):

$$\begin{aligned} \langle r_i, r_{j+1} \rangle &= \langle r_i, r_j - \alpha_j A d_j \rangle = \langle r_i, r_j \rangle - \alpha_j \langle r_i, A d_j \rangle \\ &\quad - \alpha_j \langle r_i, A d_j \rangle \end{aligned}$$

Леммы для сходимости



i Лемма 7. Коэффициенты для процесса Грама-Шмидта для CG

В процессе Грама-Шмидта для CG

$$\beta_{ji} = \frac{\langle r_i, r_i \rangle}{r_{i-1}, r_{i-1}}, \quad i = j + 1.$$

Все остальные коэффициенты равны нулю кроме $i = j$, но этот случай нам неинтересен.

Рассмотрим процесс Грам-Шмидта в методе CG

$$\beta_{ji} = -\frac{\langle d_j, u_i \rangle_A}{\langle d_j, d_j \rangle_A} = -\frac{d_j^T A u_i}{d_j^T A d_j} = -\frac{d_j^T A r_i}{d_j^T A d_j} = -\frac{r_i^T A d_j}{d_j^T A d_j}.$$

Рассмотрим скалярное произведение $\langle r_i, r_{j+1} \rangle$ используя (13):

$$\begin{aligned} \langle r_i, r_{j+1} \rangle &= \langle r_i, r_j - \alpha_j A d_j \rangle = \langle r_i, r_j \rangle - \alpha_j \langle r_i, A d_j \rangle \\ \alpha_j \langle r_i, A d_j \rangle &= \langle r_i, r_j \rangle - \langle r_i, r_{j+1} \rangle \end{aligned}$$

Леммы для сходимости



1. Если $i = j$: $\alpha_i \langle r_i, Ad_i \rangle = \langle r_i, r_i \rangle - \langle r_i, r_{i+1} \rangle = \langle r_i, r_i \rangle$. Этот случай не интересен по построению процесса Грам-Шмидта.

Леммы для сходимости



1. Если $i = j$: $\alpha_i \langle r_i, Ad_i \rangle = \langle r_i, r_i \rangle - \langle r_i, r_{i+1} \rangle = \langle r_i, r_i \rangle$. Этот случай не интересен по построению процесса Грам-Шмидта.
2. Соседний случай $i = j + 1$: $\alpha_j \langle r_i, Ad_j \rangle = \langle r_i, r_{i-1} \rangle - \langle r_i, r_i \rangle = -\langle r_i, r_i \rangle$

Леммы для сходимости



1. Если $i = j$: $\alpha_i \langle r_i, Ad_i \rangle = \langle r_i, r_i \rangle - \langle r_i, r_{i+1} \rangle = \langle r_i, r_i \rangle$. Этот случай не интересен по построению процесса Грам-Шмидта.
2. Соседний случай $i = j + 1$: $\alpha_j \langle r_i, Ad_j \rangle = \langle r_i, r_{i-1} \rangle - \langle r_i, r_i \rangle = -\langle r_i, r_i \rangle$
3. Для любого другого случая: $\alpha_j \langle r_i, Ad_j \rangle = 0$, потому что все невязки ортогональны друг другу.

Леммы для сходимости



1. Если $i = j$: $\alpha_i \langle r_i, Ad_i \rangle = \langle r_i, r_i \rangle - \langle r_i, r_{i+1} \rangle = \langle r_i, r_i \rangle$. Этот случай не интересен по построению процесса Грам-Шмидта.
2. Соседний случай $i = j + 1$: $\alpha_j \langle r_i, Ad_j \rangle = \langle r_i, r_{i-1} \rangle - \langle r_i, r_i \rangle = -\langle r_i, r_i \rangle$
3. Для любого другого случая: $\alpha_j \langle r_i, Ad_j \rangle = 0$, потому что все невязки ортогональны друг другу.

Леммы для сходимости

1. Если $i = j$: $\alpha_i \langle r_i, Ad_i \rangle = \langle r_i, r_i \rangle - \langle r_i, r_{i+1} \rangle = \langle r_i, r_i \rangle$. Этот случай не интересен по построению процесса Грам-Шмидта.
2. Соседний случай $i = j + 1$: $\alpha_j \langle r_i, Ad_j \rangle = \langle r_i, r_{i-1} \rangle - \langle r_i, r_i \rangle = -\langle r_i, r_i \rangle$
3. Для любого другого случая: $\alpha_j \langle r_i, Ad_j \rangle = 0$, потому что все невязки ортогональны друг другу.

Наконец, мы имеем формулу для $i = j + 1$:

$$\beta_{ji} = -\frac{r_i^T Ad_j}{d_j^T Ad_j}$$

Леммы для сходимости

1. Если $i = j$: $\alpha_i \langle r_i, Ad_i \rangle = \langle r_i, r_i \rangle - \langle r_i, r_{i+1} \rangle = \langle r_i, r_i \rangle$. Этот случай не интересен по построению процесса Грам-Шмидта.
2. Соседний случай $i = j + 1$: $\alpha_j \langle r_i, Ad_j \rangle = \langle r_i, r_{i-1} \rangle - \langle r_i, r_i \rangle = -\langle r_i, r_i \rangle$
3. Для любого другого случая: $\alpha_j \langle r_i, Ad_j \rangle = 0$, потому что все невязки ортогональны друг другу.

Наконец, мы имеем формулу для $i = j + 1$:

$$\beta_{ji} = -\frac{r_i^T Ad_j}{d_j^T Ad_j} = \frac{1}{\alpha_j} \frac{\langle r_i, r_i \rangle}{d_j^T Ad_j}$$

Леммы для сходимости

1. Если $i = j$: $\alpha_i \langle r_i, Ad_i \rangle = \langle r_i, r_i \rangle - \langle r_i, r_{i+1} \rangle = \langle r_i, r_i \rangle$. Этот случай не интересен по построению процесса Грам-Шмидта.
2. Соседний случай $i = j + 1$: $\alpha_j \langle r_i, Ad_j \rangle = \langle r_i, r_{i-1} \rangle - \langle r_i, r_i \rangle = -\langle r_i, r_i \rangle$
3. Для любого другого случая: $\alpha_j \langle r_i, Ad_j \rangle = 0$, потому что все невязки ортогональны друг другу.

Наконец, мы имеем формулу для $i = j + 1$:

$$\beta_{ji} = -\frac{r_i^T Ad_j}{d_j^T Ad_j} = \frac{1}{\alpha_j} \frac{\langle r_i, r_i \rangle}{d_j^T Ad_j} = \frac{d_j^T Ad_j}{d_j^T r_j} \frac{\langle r_i, r_i \rangle}{d_j^T Ad_j}$$

Леммы для сходимости

1. Если $i = j$: $\alpha_i \langle r_i, Ad_i \rangle = \langle r_i, r_i \rangle - \langle r_i, r_{i+1} \rangle = \langle r_i, r_i \rangle$. Этот случай не интересен по построению процесса Грам-Шмидта.
2. Соседний случай $i = j + 1$: $\alpha_j \langle r_i, Ad_j \rangle = \langle r_i, r_{i-1} \rangle - \langle r_i, r_i \rangle = -\langle r_i, r_i \rangle$
3. Для любого другого случая: $\alpha_j \langle r_i, Ad_j \rangle = 0$, потому что все невязки ортогональны друг другу.

Наконец, мы имеем формулу для $i = j + 1$:

$$\beta_{ji} = -\frac{r_i^T Ad_j}{d_j^T Ad_j} = \frac{1}{\alpha_j} \frac{\langle r_i, r_i \rangle}{d_j^T Ad_j} = \frac{d_j^T Ad_j}{d_j^T r_j} \frac{\langle r_i, r_i \rangle}{d_j^T Ad_j} = \frac{\langle r_i, r_i \rangle}{\langle r_j, r_j \rangle}$$

Леммы для сходимости

1. Если $i = j$: $\alpha_i \langle r_i, Ad_i \rangle = \langle r_i, r_i \rangle - \langle r_i, r_{i+1} \rangle = \langle r_i, r_i \rangle$. Этот случай не интересен по построению процесса Грам-Шмидта.
2. Соседний случай $i = j + 1$: $\alpha_j \langle r_i, Ad_j \rangle = \langle r_i, r_{i-1} \rangle - \langle r_i, r_i \rangle = -\langle r_i, r_i \rangle$
3. Для любого другого случая: $\alpha_j \langle r_i, Ad_j \rangle = 0$, потому что все невязки ортогональны друг другу.

Наконец, мы имеем формулу для $i = j + 1$:

$$\beta_{ji} = -\frac{r_i^T Ad_j}{d_j^T Ad_j} = \frac{1}{\alpha_j} \frac{\langle r_i, r_i \rangle}{d_j^T Ad_j} = \frac{d_j^T Ad_j}{d_j^T r_j} \frac{\langle r_i, r_i \rangle}{d_j^T Ad_j} = \frac{\langle r_i, r_i \rangle}{\langle r_j, r_j \rangle} = \frac{\langle r_i, r_i \rangle}{\langle r_{i-1}, r_{i-1} \rangle}$$

Леммы для сходимости

1. Если $i = j$: $\alpha_i \langle r_i, Ad_i \rangle = \langle r_i, r_i \rangle - \langle r_i, r_{i+1} \rangle = \langle r_i, r_i \rangle$. Этот случай не интересен по построению процесса Грам-Шмидта.
2. Соседний случай $i = j + 1$: $\alpha_j \langle r_i, Ad_j \rangle = \langle r_i, r_{i-1} \rangle - \langle r_i, r_i \rangle = -\langle r_i, r_i \rangle$
3. Для любого другого случая: $\alpha_j \langle r_i, Ad_j \rangle = 0$, потому что все невязки ортогональны друг другу.

Наконец, мы имеем формулу для $i = j + 1$:

$$\beta_{ji} = -\frac{r_i^T Ad_j}{d_j^T Ad_j} = \frac{1}{\alpha_j} \frac{\langle r_i, r_i \rangle}{d_j^T Ad_j} = \frac{d_j^T Ad_j}{d_j^T r_j} \frac{\langle r_i, r_i \rangle}{d_j^T Ad_j} = \frac{\langle r_i, r_i \rangle}{\langle r_j, r_j \rangle} = \frac{\langle r_i, r_i \rangle}{\langle r_{i-1}, r_{i-1} \rangle}$$

Леммы для сходимости

1. Если $i = j$: $\alpha_i \langle r_i, Ad_i \rangle = \langle r_i, r_i \rangle - \langle r_i, r_{i+1} \rangle = \langle r_i, r_i \rangle$. Этот случай не интересен по построению процесса Грам-Шмидта.
2. Соседний случай $i = j + 1$: $\alpha_j \langle r_i, Ad_j \rangle = \langle r_i, r_{i-1} \rangle - \langle r_i, r_i \rangle = -\langle r_i, r_i \rangle$
3. Для любого другого случая: $\alpha_j \langle r_i, Ad_j \rangle = 0$, потому что все невязки ортогональны друг другу.

Наконец, мы имеем формулу для $i = j + 1$:

$$\beta_{ji} = -\frac{r_i^T Ad_j}{d_j^T Ad_j} = \frac{1}{\alpha_j} \frac{\langle r_i, r_i \rangle}{d_j^T Ad_j} = \frac{d_j^T Ad_j}{d_j^T r_j} \frac{\langle r_i, r_i \rangle}{d_j^T Ad_j} = \frac{\langle r_i, r_i \rangle}{\langle r_j, r_j \rangle} = \frac{\langle r_i, r_i \rangle}{\langle r_{i-1}, r_{i-1} \rangle}$$

И для направления $d_{k+1} = r_{k+1} + \beta_{k,k+1} d_k$, $\beta_{k,k+1} = \beta_k = \frac{\langle r_{k+1}, r_{k+1} \rangle}{\langle r_k, r_k \rangle}$.