



### Метод Ньютона



େ ପ ବ


Рассмотрим функцию  $\varphi(x): \mathbb{R} \to \mathbb{R}$ .





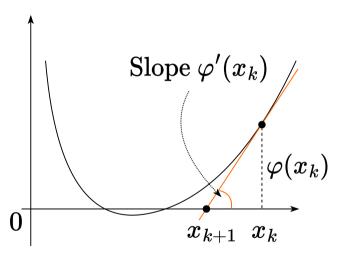
Рассмотрим функцию  $\varphi(x):\mathbb{R} \to \mathbb{R}.$  Основная идея заключается в том, чтобы построить линейное приближение в точке  $x_k$  и найти его корень, который будет новой точкой итерации:

**⊕** O **0** 



Рассмотрим функцию  $\varphi(x):\mathbb{R}\to\mathbb{R}.$  Основная идея заключается в том, чтобы построить линейное приближение в точке  $x_k$  и найти его корень, который будет новой точкой итерации:

$$\varphi'(x_k) = \frac{\varphi(x_k)}{x_{k+1} - x_k}$$

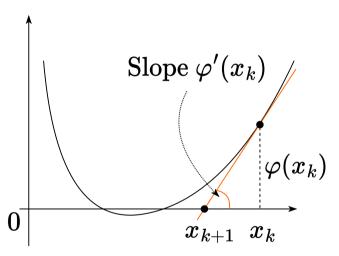


Рассмотрим функцию  $\varphi(x):\mathbb{R}\to\mathbb{R}.$  Основная идея заключается в том, чтобы построить линейное приближение в точке  $x_k$  и найти его корень, который будет новой точкой итерации:

$$\varphi'(x_k) = \frac{\varphi(x_k)}{x_{k+1} - x_k}$$

Мы получаем итерационную схему:

⊕ n a




Рассмотрим функцию  $\varphi(x):\mathbb{R}\to\mathbb{R}.$  Основная идея заключается в том, чтобы построить линейное приближение в точке  $x_k$  и найти его корень, который будет новой точкой итерации:

$$\varphi'(x_k) = \frac{\varphi(x_k)}{x_{k+1} - x_k}$$


Мы получаем итерационную схему:

$$x_{k+1} = x_k - \frac{\varphi(x_k)}{\varphi'(x_k)}.$$

 $<sup>^{1}</sup>$ Мы фактически решаем задачу нахождения стационарных точек abla f(x)=0







Рассмотрим функцию  $\varphi(x):\mathbb{R}\to\mathbb{R}.$  Основная идея заключается в том, чтобы построить линейное приближение в точке  $x_k$  и найти его корень, который будет новой точкой итерации:

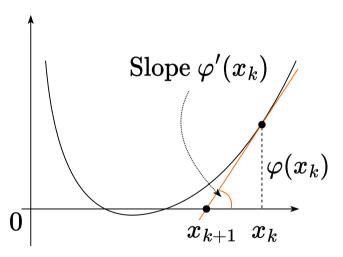
$$\varphi'(x_k) = \frac{\varphi(x_k)}{x_{k+1} - x_k}$$

Мы получаем итерационную схему:

$$x_{k+1} = x_k - \frac{\varphi(x_k)}{\varphi'(x_k)}.$$

Этот метод станет методом оптимизации Ньютона в случае  $f'(x) = \varphi(x)^1$ :

 $<sup>^{1}</sup>$ Мы фактически решаем задачу нахождения стационарных точек abla f(x)=0



Рассмотрим функцию  $\varphi(x):\mathbb{R}\to\mathbb{R}.$  Основная идея заключается в том, чтобы построить линейное приближение в точке  $x_k$  и найти его корень, который будет новой точкой итерации:

$$\varphi'(x_k) = \frac{\varphi(x_k)}{x_{k+1} - x_k}$$

Мы получаем итерационную схему:

$$x_{k+1} = x_k - \frac{\varphi(x_k)}{\varphi'(x_k)}.$$

Этот метод станет методом оптимизации Ньютона в случае  $f'(x)=arphi(x)^1$ :

$$x_{k+1} = x_k - \left[\nabla^2 f(x_k)\right]^{-1} \nabla f(x_k)$$

 $<sup>^1</sup>$ Мы фактически решаем задачу нахождения стационарных точек abla f(x) = 0





Пусть у нас есть функция f(x) и некоторая точка  $x_k$ . Рассмотрим квадратичное приближение этой функции в окрестности  $x_k$ :

**♥ ೧ 0** 

Пусть у нас есть функция f(x) и некоторая точка  $x_b$ . Рассмотрим квадратичное приближение этой функции в окрестности  $x_{\nu}$ :

$$f^{II}_{x_k}(x) = f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle.$$

Пусть у нас есть функция f(x) и некоторая точка  $x_b$ . Рассмотрим квадратичное приближение этой функции в окрестности  $x_{k}$ :

$$f^{II}_{x_k}(x) = f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle.$$

Идея метода заключается в том, чтобы найти точку  $x_{k+1}$ , которая минимизирует функцию  $f_{x_k}^{II}(x)$ , т.е.  $\nabla f_{x_{i}}^{II}(x_{k+1}) = 0.$ 

Пусть у нас есть функция f(x) и некоторая точка  $x_b$ . Рассмотрим квадратичное приближение этой функции в окрестности  $x_{k}$ :

$$f^{II}_{x_k}(x) = f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle.$$

Идея метода заключается в том, чтобы найти точку  $x_{k+1}$ , которая минимизирует функцию  $f_{I}^{II}(x)$ , т.е.  $\nabla f_{x_{k}}^{II}(x_{k+1}) = 0.$ 

$$\nabla f_{x_k}^{II}(x_{k+1}) = \nabla f(x_k) + \nabla^2 f(x_k)(x_{k+1} - x_k) = 0$$

Пусть у нас есть функция f(x) и некоторая точка  $x_k$ . Рассмотрим квадратичное приближение этой функции в окрестности  $x_{k}$ :

$$f_{x_k}^{II}(x) = f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle.$$

Идея метода заключается в том, чтобы найти точку  $x_{k+1}$ , которая минимизирует функцию  $f_{I}^{II}(x)$ , т.е.  $\nabla f_{x_{k}}^{II}(x_{k+1}) = 0.$ 

$$\nabla f^{II}_{x_k}(x_{k+1}) = \nabla f(x_k) + \nabla^2 f(x_k)(x_{k+1} - x_k) = 0$$
 
$$\nabla^2 f(x_k)(x_{k+1} - x_k) = -\nabla f(x_k)$$

Пусть у нас есть функция f(x) и некоторая точка  $x_k$ . Рассмотрим квадратичное приближение этой функции в окрестности  $x_{k}$ :

$$f^{II}_{x_k}(x) = f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle.$$

Идея метода заключается в том, чтобы найти точку  $x_{k+1}$ , которая минимизирует функцию  $f_{I}^{II}(x)$ , т.е.  $\nabla f_{x_{k}}^{II}(x_{k+1}) = 0.$ 

$$\begin{split} \nabla f^{II}_{x_k}(x_{k+1}) &= \nabla f(x_k) + \nabla^2 f(x_k)(x_{k+1} - x_k) = 0 \\ \nabla^2 f(x_k)(x_{k+1} - x_k) &= -\nabla f(x_k) \\ \left[\nabla^2 f(x_k)\right]^{-1} \nabla^2 f(x_k)(x_{k+1} - x_k) &= -\left[\nabla^2 f(x_k)\right]^{-1} \nabla f(x_k) \end{split}$$

 $f \to \min_{x,y,z}$  Метод Ньютона

Пусть у нас есть функция f(x) и некоторая точка  $x_k$ . Рассмотрим квадратичное приближение этой функции в окрестности  $x_{k}$ :

$$f^{II}_{x_k}(x) = f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle.$$

Идея метода заключается в том, чтобы найти точку  $x_{k+1}$ , которая минимизирует функцию  $f_{I}^{II}(x)$ , т.е.  $\nabla f_{x_{k}}^{II}(x_{k+1}) = 0.$ 

$$\begin{split} \nabla f^{II}_{x_k}(x_{k+1}) &= \nabla f(x_k) + \nabla^2 f(x_k)(x_{k+1} - x_k) = 0 \\ \nabla^2 f(x_k)(x_{k+1} - x_k) &= -\nabla f(x_k) \\ \left[\nabla^2 f(x_k)\right]^{-1} \nabla^2 f(x_k)(x_{k+1} - x_k) &= -\left[\nabla^2 f(x_k)\right]^{-1} \nabla f(x_k) \\ x_{k+1} &= x_k - \left[\nabla^2 f(x_k)\right]^{-1} \nabla f(x_k). \end{split}$$

 $f \to \min_{x,y,z}$  Метод Ньютона

Пусть у нас есть функция f(x) и некоторая точка  $x_k$ . Рассмотрим квадратичное приближение этой функции в окрестности  $x_{k}$ :

$$f^{II}_{x_k}(x) = f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle.$$

Идея метода заключается в том, чтобы найти точку  $x_{k+1}$ , которая минимизирует функцию  $f_{I}^{II}(x)$ , т.е.  $\nabla f_{x_{k}}^{II}(x_{k+1}) = 0.$ 

$$\begin{split} \nabla f^{II}_{x_k}(x_{k+1}) &= \nabla f(x_k) + \nabla^2 f(x_k)(x_{k+1} - x_k) = 0 \\ \nabla^2 f(x_k)(x_{k+1} - x_k) &= -\nabla f(x_k) \\ \left[\nabla^2 f(x_k)\right]^{-1} \nabla^2 f(x_k)(x_{k+1} - x_k) &= -\left[\nabla^2 f(x_k)\right]^{-1} \nabla f(x_k) \\ x_{k+1} &= x_k - \left[\nabla^2 f(x_k)\right]^{-1} \nabla f(x_k). \end{split}$$

 $f \to \min_{x,y,z}$  Метод Ньютона

Пусть у нас есть функция f(x) и некоторая точка  $x_k$ . Рассмотрим квадратичное приближение этой функции в окрестности  $x_k$ :


$$f_{x_k}^{II}(x) = f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle.$$


 $\nabla f_{x_{k}}^{II}(x_{k+1}) = \nabla f(x_{k}) + \nabla^{2} f(x_{k})(x_{k+1} - x_{k}) = 0$ 

Идея метода заключается в том, чтобы найти точку  $x_{k+1}$ , которая минимизирует функцию  $f^{II}_{x_k}(x)$ , т.е.  $\nabla f^{II}_{x_k}(x_{k+1}) = 0$ .


$$\begin{split} \nabla^2 f(x_k)(x_{k+1}-x_k) &= -\nabla f(x_k) \\ \left[\nabla^2 f(x_k)\right]^{-1} \nabla^2 f(x_k)(x_{k+1}-x_k) &= -\left[\nabla^2 f(x_k)\right]^{-1} \nabla f(x_k) \\ x_{k+1} &= x_k - \left[\nabla^2 f(x_k)\right]^{-1} \nabla f(x_k). \end{split}$$

Необходимо отметить ограничения, связанные с необходимостью невырожденности (для существования метода) и положительной определенности (для гарантии сходимости) гессиана.








**⊕ ೧ 0** 



Метод Ньютона







**♥೧**0

#### **i** Theorem

Пусть f(x) — сильно выпуклая дважды непрерывно дифференцируемая функция на  $\mathbb{R}^n$ , для второй производной которой выполняются неравенства:  $\mu I_n \preceq \nabla^2 f(x) \preceq L I_n$ . Пусть также гессиан функции M-липшицев. Тогда метод Ньютона сходится локально к решению с квадратичной скоростью, т.е. при  $\|x_0-x^*\|<\frac{2\mu}{2M}$ :

$$\|x_{k+1} - x^*\| \le \frac{3M}{2\mu} \|x_k - x^*\|^2$$

### i Theorem

Пусть f(x) — сильно выпуклая дважды непрерывно дифференцируемая функция на  $\mathbb{R}^n$ , для второй производной которой выполняются неравенства:  $\mu I_n \preceq \nabla^2 f(x) \preceq L I_n$ . Пусть также гессиан функции M-липшицев. Тогда метод Ньютона сходится локально к решению с квадратичной скоростью, т.е. при  $\|x_0-x^*\|<\frac{2\mu}{2M}$ :

$$\|x_{k+1} - x^*\| \le \frac{3M}{2\mu} \|x_k - x^*\|^2$$

#### Доказательство

େ 💎 ମ 🛮

### i Theorem

Пусть f(x) — сильно выпуклая дважды непрерывно дифференцируемая функция на  $\mathbb{R}^n$ , для второй производной которой выполняются неравенства:  $\mu I_n \preceq \nabla^2 f(x) \preceq L I_n$ . Пусть также гессиан функции M-липшицев. Тогда метод Ньютона сходится локально к решению с квадратичной скоростью, т.е. при  $\|x_0 - x^*\| < \frac{2\mu}{2M}$ :

$$\|x_{k+1} - x^*\| \le \frac{3M}{2\mu} \|x_k - x^*\|^2$$

#### Доказательство

1. Мы будем использовать формулу Ньютона-Лейбница

$$\nabla f(x_k) - \nabla f(x^*) = \int_0^1 \nabla^2 f(x^* + \tau(x_k - x^*))(x_k - x^*) d\tau$$

େନ୍ତ

### 1 Theorem

Пусть f(x) — сильно выпуклая дважды непрерывно дифференцируемая функция на  $\mathbb{R}^n$ , для второй производной которой выполняются неравенства:  $\mu I_n \preceq \nabla^2 f(x) \preceq L I_n$ . Пусть также гессиан функции M-липшицев. Тогда метод Ньютона сходится локально к решению с квадратичной скоростью, т.е. при  $||x_0 - x^*|| < \frac{2\mu}{2M}$ :

$$\|x_{k+1} - x^*\| \le \frac{3M}{2\mu} \|x_k - x^*\|^2$$

#### Доказательство

1. Мы будем использовать формулу Ньютона-Лейбница

$$\nabla f(x_k) - \nabla f(x^*) = \int_0^1 \nabla^2 f(x^* + \tau(x_k - x^*))(x_k - x^*) d\tau$$

2. Мы будем отслеживать расстояние до решения

### 1 Theorem

Пусть f(x) — сильно выпуклая дважды непрерывно дифференцируемая функция на  $\mathbb{R}^n$ , для второй производной которой выполняются неравенства:  $\mu I_n \preceq \nabla^2 f(x) \preceq L I_n$ . Пусть также гессиан функции M-липшицев. Тогда метод Ньютона сходится локально к решению с квадратичной скоростью, т.е. при  $||x_0 - x^*|| < \frac{2\mu}{2M}$ :

$$\|x_{k+1} - x^*\| \le \frac{3M}{2\mu} \|x_k - x^*\|^2$$

#### Доказательство

1. Мы будем использовать формулу Ньютона-Лейбница

$$\nabla f(x_k) - \nabla f(x^*) = \int_0^1 \nabla^2 f(x^* + \tau(x_k - x^*))(x_k - x^*) d\tau$$

2. Мы будем отслеживать расстояние до решения

$$(x_{t+1} - x^* = x_t - [\nabla^2 f(x_t)]^{-1} \nabla f(x_t) - x^* = x_t - x^* - [\nabla^2 f(x_t)]^{-1} \nabla f(x_t) = x_t - x$$

### i Theorem

Пусть f(x) — сильно выпуклая дважды непрерывно дифференцируемая функция на  $\mathbb{R}^n$ , для второй производной которой выполняются неравенства:  $\mu I_n \preceq \nabla^2 f(x) \preceq L I_n$ . Пусть также гессиан функции M-липшицев. Тогда метод Ньютона сходится локально к решению с квадратичной скоростью, т.е. при  $\|x_0-x^*\|<\frac{2\mu}{2M}$ :

$$||x_{k+1} - x^*|| \le \frac{3M}{2\mu} ||x_k - x^*||^2$$

#### Доказательство

1. Мы будем использовать формулу Ньютона-Лейбница

$$\nabla f(x_k) - \nabla f(x^*) = \int^1 \nabla^2 f(x^* + \tau(x_k - x^*))(x_k - x^*) d\tau$$

2. Мы будем отслеживать расстояние до решения

$$\begin{split} x_{k+1} - x^* &= x_k - \left[\nabla^2 f(x_k)\right]^{-1} \nabla f(x_k) - x^* = x_k - x^* - \left[\nabla^2 f(x_k)\right]^{-1} \nabla f(x_k) = \\ &= x_k - x^* - \left[\nabla^2 f(x_k)\right]^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x_k - x^*))(x_k - x^*) d\tau \end{split}$$

$$= \left(I - \left[\nabla^2 f(x_k)\right]^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x_k - x^*)) d\tau \right) (x_k - x^*) =$$

$$\begin{split} &= \left(I - \left[\nabla^2 f(x_k)\right]^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x_k - x^*)) d\tau\right) (x_k - x^*) = \\ &= \left[\nabla^2 f(x_k)\right]^{-1} \left(\nabla^2 f(x_k) - \int_0^1 \nabla^2 f(x^* + \tau(x_k - x^*)) d\tau\right) (x_k - x^*) = \end{split}$$



$$\begin{split} &= \left(I - \left[\nabla^2 f(x_k)\right]^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x_k - x^*)) d\tau\right) (x_k - x^*) = \\ &= \left[\nabla^2 f(x_k)\right]^{-1} \left(\nabla^2 f(x_k) - \int_0^1 \nabla^2 f(x^* + \tau(x_k - x^*)) d\tau\right) (x_k - x^*) = \\ &= \left[\nabla^2 f(x_k)\right]^{-1} \left(\int_0^1 \left(\nabla^2 f(x_k) - \nabla^2 f(x^* + \tau(x_k - x^*)) d\tau\right) (x_k - x^*) = \\ \end{split}$$

$$\begin{split} &= \left(I - \left[\nabla^2 f(x_k)\right]^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x_k - x^*)) d\tau\right) (x_k - x^*) = \\ &= \left[\nabla^2 f(x_k)\right]^{-1} \left(\nabla^2 f(x_k) - \int_0^1 \nabla^2 f(x^* + \tau(x_k - x^*)) d\tau\right) (x_k - x^*) = \\ &= \left[\nabla^2 f(x_k)\right]^{-1} \left(\int_0^1 \left(\nabla^2 f(x_k) - \nabla^2 f(x^* + \tau(x_k - x^*)) d\tau\right) \left(x_k - x^*\right) = \\ &= \left[\nabla^2 f(x_k)\right]^{-1} G_k(x_k - x^*) \end{split}$$

3.

$$\begin{split} &= \left(I - \left[\nabla^2 f(x_k)\right]^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x_k - x^*)) d\tau\right) (x_k - x^*) = \\ &= \left[\nabla^2 f(x_k)\right]^{-1} \left(\nabla^2 f(x_k) - \int_0^1 \nabla^2 f(x^* + \tau(x_k - x^*)) d\tau\right) (x_k - x^*) = \\ &= \left[\nabla^2 f(x_k)\right]^{-1} \left(\int_0^1 \left(\nabla^2 f(x_k) - \nabla^2 f(x^* + \tau(x_k - x^*)) d\tau\right) (x_k - x^*) = \\ &= \left[\nabla^2 f(x_k)\right]^{-1} G_b(x_k - x^*) \end{split}$$

4. Введём:

$$G_k = \int_0^1 \left( \nabla^2 f(x_k) - \nabla^2 f(x^* + \tau(x_k - x^*)) d\tau \right).$$

5. Попробуем оценить размер  $G_k$  с помощью  $r_k = \|x_k - x^*\|$ :

5. Попробуем оценить размер  $G_k$  с помощью  $r_k = \|x_k - x^*\|$ :

$$\|G_k\| = \left\|\int_0^1 \left(\nabla^2 f(x_k) - \nabla^2 f(x^* + \tau(x_k - x^*))d\tau\right)\right\| \leq$$

5. Попробуем оценить размер  $G_k$  с помощью  $r_k = \|x_k - x^*\|$ :

$$\|G_k\| = \left\|\int_0^1 \left(\nabla^2 f(x_k) - \nabla^2 f(x^* + \tau(x_k - x^*))d\tau\right)\right\| \leq$$

$$\leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k}) - 
abla^{2}f(x^{*} + au(x_{k} - x^{*})) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k}) - 
abla^{2}f(x^{*} + au(x_{k} - x^{*})) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k}) - 
abla^{2}f(x^{*} + au(x_{k} - x^{*})) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k}) - 
abla^{2}f(x^{*} + au(x_{k} - x^{*})) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k}) - 
abla^{2}f(x^{*} + au(x_{k} - x^{*})) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k}) - 
abla^{2}f(x^{*} + au(x_{k} - x^{*})) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k}) - 
abla^{2}f(x^{*} + au(x_{k} - x^{*})) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k}) - 
abla^{2}f(x^{*} + au(x_{k} - x^{*})) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k}) - 
abla^{2}f(x_{k} - x^{*}) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k} - x^{*}) - 
abla^{2}f(x_{k} - x^{*}) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k} - x^{*}) - 
abla^{2}f(x_{k} - x^{*}) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k} - x^{*}) - 
abla^{2}f(x_{k} - x^{*}) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k} - x^{*}) - 
abla^{2}f(x_{k} - x^{*}) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k} - x^{*}) - 
abla^{2}f(x_{k} - x^{*}) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k} - x^{*}) - 
abla^{2}f(x_{k} - x^{*}) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k} - x^{*}) - 
abla^{2}f(x_{k} - x^{*}) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k} - x^{*}) - 
abla^{2}f(x_{k} - x^{*}) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k} - x^{*}) - 
abla^{2}f(x_{k} - x^{*}) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k} - x^{*}) - 
abla^{2}f(x_{k} - x^{*}) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k} - x^{*}) - 
abla^{2}f(x_{k} - x^{*}) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k} - x^{*}) - 
abla^{2}f(x_{k} - x^{*}) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k} - x^{*}) - 
abla^{2}f(x_{k} - x^{*}) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k} - x^{*}) - 
abla^{2}f(x_{k} - x^{*}) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k} - x^{*}) - 
abla^{2}f(x_{k} - x^{*}) 
ight\| d au \leq \int_{0}^{1}\left\| 
abla^{2}f(x_{k} - x^{*}) - 
abla^{2}f(x_{k} - x^{*}) 
ight\| d au \leq \int_{0}^{1}$$

5. Попробуем оценить размер  $G_k$  с помощью  $r_k = \|x_k - x^*\|$ :

$$\|G_k\| = \left\| \int_0^1 \left( \nabla^2 f(x_k) - \nabla^2 f(x^* + \tau(x_k - x^*)) d\tau \right) \right\| \leq \\ \leq \int_0^1 \left\| \nabla^2 f(x_k) - \nabla^2 f(x^* + \tau(x_k - x^*)) \right\| d\tau \leq \qquad \text{(Липшицевость гессиана)} \\ \leq \int_0^1 M \|x_k - x^* - \tau(x_k - x^*)\| d\tau = \int_0^1 M \|x_k - x^*\| (1 - \tau) d\tau = \frac{r_k}{2} M,$$

5. Попробуем оценить размер  $G_k$  с помощью  $r_k = \|x_k - x^*\|$ :

$$\begin{split} \|G_k\| &= \left\| \int_0^1 \left( \nabla^2 f(x_k) - \nabla^2 f(x^* + \tau(x_k - x^*)) d\tau \right) \right\| \leq \\ &\leq \int_0^1 \left\| \nabla^2 f(x_k) - \nabla^2 f(x^* + \tau(x_k - x^*)) \right\| d\tau \leq & \text{ (Липшицевость гессиана)} \\ &\leq \int_0^1 M \|x_k - x^* - \tau(x_k - x^*)\| d\tau = \int_0^1 M \|x_k - x^*\| (1 - \tau) d\tau = \frac{r_k}{2} M, \end{split}$$

6. Получаем:

$$r_{k+1} \leq \left\| \left[ \nabla^2 f(x_k) \right]^{-1} \right\| \cdot \frac{r_k}{2} M \cdot r_k$$

и нам нужно оценить норму обратного гессиана

**Сходимость** 7. Из липшицевости и симметричности

гессиана:

7. Из липшицевости и симметричности гессиана:

$$\nabla^2 f(x_k) - \nabla^2 f(x^*) \succeq -M r_k I_n$$

7. Из липшицевости и симметричности гессиана:

$$\begin{split} \nabla^2 f(x_k) - \nabla^2 f(x^*) &\succeq -M r_k I_n \\ \nabla^2 f(x_k) &\succeq \nabla^2 f(x^*) - M r_k I_n \end{split}$$

7. Из липшицевости и симметричности гессиана:

$$\begin{split} \nabla^2 f(x_k) - \nabla^2 f(x^*) \succeq -M r_k I_n \\ \nabla^2 f(x_k) \succeq \nabla^2 f(x^*) - M r_k I_n \\ \nabla^2 f(x_k) \succeq \mu I_n - M r_k I_n \end{split}$$

େ ଓ ଓ

7. Из липшицевости и симметричности гессиана:

$$\begin{split} \nabla^2 f(x_k) - \nabla^2 f(x^*) \succeq -M r_k I_n \\ \nabla^2 f(x_k) \succeq \nabla^2 f(x^*) - M r_k I_n \\ \nabla^2 f(x_k) \succeq \mu I_n - M r_k I_n \\ \nabla^2 f(x_k) \succeq (\mu - M r_k) I_n \end{split}$$

7. Из липшицевости и симметричности гессиана:

$$\begin{split} \nabla^2 f(x_k) - \nabla^2 f(x^*) \succeq -M r_k I_n \\ \nabla^2 f(x_k) \succeq \nabla^2 f(x^*) - M r_k I_n \\ \nabla^2 f(x_k) \succeq \mu I_n - M r_k I_n \\ \nabla^2 f(x_k) \succeq (\mu - M r_k) I_n \end{split}$$

8. Из сильной выпуклости следует, что  $\nabla^2 f(x_k) \succ 0$ , i.e.  $r_k < \frac{\mu}{M}$ .

$$\begin{split} \left\| \left[ \nabla^2 f(x_k) \right]^{-1} \right\| &\leq (\mu - M r_k)^{-1} \\ r_{k+1} &\leq \frac{r_k^2 M}{2(\mu - M r_k)} \end{split}$$

7. Из липшицевости и симметричности гессиана:

$$\begin{split} \nabla^2 f(x_k) - \nabla^2 f(x^*) \succeq -M r_k I_n \\ \nabla^2 f(x_k) \succeq \nabla^2 f(x^*) - M r_k I_n \\ \nabla^2 f(x_k) \succeq \mu I_n - M r_k I_n \\ \nabla^2 f(x_k) \succeq (\mu - M r_k) I_n \end{split}$$

8. Из сильной выпуклости следует, что  $\nabla^2 f(x_L) > 0$ , i.e.  $r_L < \frac{\mu}{M}$ .

$$\begin{split} \left\| \left[ \nabla^2 f(x_k) \right]^{-1} \right\| & \leq (\mu - M r_k)^{-1} \\ r_{k+1} & \leq \frac{r_k^2 M}{2(\mu - M r_k)} \end{split}$$

9. Потребуем, чтобы верхняя оценка на  $r_{k+1}$  была меньше  $r_k$ , учитывая, что  $0 < r_k < \frac{\mu}{M}$ :

$$\begin{split} \frac{r_k^2 M}{2(\mu - M r_k)} &< r_k \\ \frac{M}{2(\mu - M r_k)} \, r_k &< 1 \\ M r_k &< 2(\mu - M r_k) \\ 3M r_k &< 2\mu \\ r_k &< \frac{2\mu}{3M} \end{split}$$



7. Из липшицевости и симметричности гессиана:

$$\begin{split} \nabla^2 f(x_k) - \nabla^2 f(x^*) \succeq -M r_k I_n \\ \nabla^2 f(x_k) \succeq \nabla^2 f(x^*) - M r_k I_n \\ \nabla^2 f(x_k) \succeq \mu I_n - M r_k I_n \\ \nabla^2 f(x_k) \succeq (\mu - M r_k) I_n \end{split}$$

8. Из сильной выпуклости следует, что  $\nabla^2 f(x_L) > 0$ , i.e.  $r_L < \frac{\mu}{M}$ .

$$\begin{split} \left\| \left[ \nabla^2 f(x_k) \right]^{-1} \right\| &\leq (\mu - M r_k)^{-1} \\ r_{k+1} &\leq \frac{r_k^2 M}{2(\mu - M r_k)} \end{split}$$

Потребуем, чтобы верхняя оценка на  $r_{k+1}$  была меньше  $r_k$ , учитывая, что  $0 < r_k < \frac{\mu}{M}$ :

$$\begin{split} \frac{r_k^2M}{2(\mu-Mr_k)} &< r_k \\ \frac{M}{2(\mu-Mr_k)} \, r_k &< 1 \\ Mr_k &< 2(\mu-Mr_k) \\ 3Mr_k &< 2\mu \\ r_k &< \frac{2\mu}{3M} \end{split}$$

10. Возвращаясь к оценке невязки на k+1-ой итерации, получаем:

$$r_{k+1} \le \frac{r_k^2 M}{2(\mu - M r_k)} < \frac{3M r_k^2}{2\mu}$$

Таким образом, мы получили важный результат: метод Ньютона для функции с липшицевым положительно определённым гессианом сходится квадратично вблизи решения.

# Свойства метода Ньютона






# Отсутствие квадратичной сходимости, если некоторые предположения нарушаются

i


$$f(x)=x^4 \qquad f'(x)=4x^3 \qquad f''(x)=12x^2$$



$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)} = x_k - \frac{4x_k^3}{12x_k^2} = x_k - \frac{1}{3}x_k = \frac{2}{3}x_k,$$

сходится линейно к 0, единственному решению задачи, с линейной скоростью.

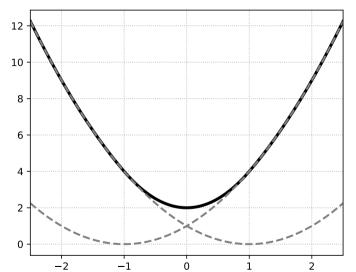
# Локальная сходимость метода Ньютона для гладкой сильно выпуклой f(x)



$$f(x) = \begin{cases} (x-1)^2, & x \le -1\\ 2x^2 + 2, & -1 < x < 1\\ (x+1)^2, & x \ge 1 \end{cases}$$


Эта функция сильно выпукла, но вторая производная не является липшицевой.

# Локальная сходимость метода Ньютона для гладкой сильно выпуклой f(x)

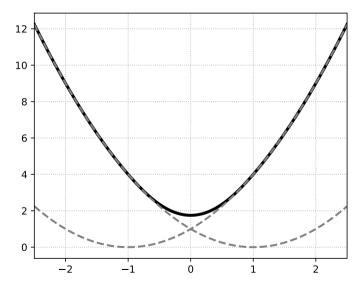


$$f(x) = \begin{cases} (x-1)^2, & x \le -1\\ 2x^2 + 2, & -1 < x < 1\\ (x+1)^2, & x \ge 1 \end{cases}$$

Эта функция сильно выпукла, но вторая производная не является липшицевой.





# Локальная сходимость метода Ньютона даже если $\nabla^2 f$ липшицев




$$f(x) = \begin{cases} (x-1)^2, & x \le -1\\ -\frac{1}{4}x^4 + \frac{5}{2}x^2 + \frac{7}{4}, & -1 < x < 1\\ (x+1)^2, & x \ge 1 \end{cases}$$

Эта функция сильно выпукла и вторая производная является липшицевой.





















































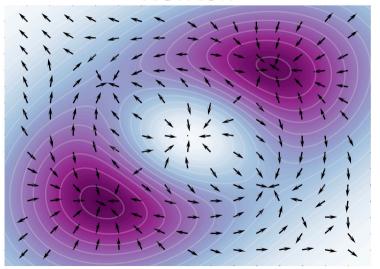




# Проблемы метода Ньютона


Свойства метода Ньютона

# Newton





#### Проблемы метода Ньютона



# Метод Ньютона для квадратичной задачи (линейной регрессии)

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} x^\top A x - b^\top x, \qquad A \in \mathbb{R}^{n \times n}, \quad \lambda\left(A\right) \in [\mu; L].$$

Strongly convex quadratics: n=60, random matrix,  $\mu$ =1, L=10




Рис. 3: Так как задача - квадратичная, то метод Ньютона сходится за один шаг.

⊕ o o

# Метод Ньютона для квадратичной задачи (линейной регрессии)

**Function Gap** 

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} x^\top A x - b^\top x, \qquad A \in \mathbb{R}^{n \times n}, \quad \lambda\left(A\right) \in [\mu; L].$$

Convex quadratics: n=60, random matrix,  $\mu=0$ , L=10

Domain Gap

**Gradient Norm** 




Рис. 4: В этом случае метод Ньютона тоже крайне быстро сходится, однако, отметим, что это происходит благодаря тому, что минимальное собственное число гессиана не 0, а около  $10^{-8}$ . Если применять метод Ньютона в наивной форме с обращением матрицы, то получится ошибка, так как матрица вырождена. На практике все равно можно использовать метод, если для направления итерации решать линейную систему  $\nabla^2 f(x_k) d_k = -\nabla f(x_k)$  методом наименьших квадратов.

# Метод Ньютона для квадратичной задачи (линейной регрессии)

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} x^\top A x - b^\top x, \qquad A \in \mathbb{R}^{n \times n}, \quad \lambda\left(A\right) \in [\mu; L].$$

Strongly convex quadratics: n=60, random matrix,  $\mu=1$ , L=1000




Рис. 5: Здесь число обусловленности гессиана в 1000 раз больше, чем в предыдущем случае, и метод Ньютона сходится за 1 итерацию.



# Метод Ньютона для задачи бинарной логистической регрессии

Convex binary logistic regression. mu=0. m=1000, n=10.




Рис. 6: Наблюдается расходимость метода Ньютона. Сразу отметим, что в задаче нет регуляризации и гарантии сильной выпуклости. А также нет гарантий того, что мы инициализируем метод в окрестности решения.



# Метод Ньютона для задачи бинарной логистической регрессии

Strongly convex binary logistic regression. mu=0.2. m=1000, n=10.




Рис. 7: Добавление регуляризации гарантирует сильную выпуклость, наблюдается сходимость метода Ньютона.



## Метод Ньютона для задачи бинарной логистической регрессии

Strongly convex binary logistic regression. mu=0.2. m=1000, n=500.

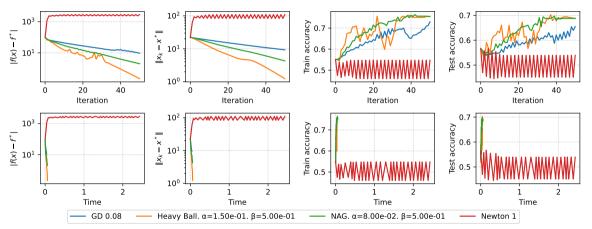


Рис. 8: Увеличим размерность в 50 раз и наблюдаем расходимость метода Ньютона. Это можно связать с тем, что мы инициализируем метод в точке, далекой от решения





## Метод Ньютона для задачи бинарной логистической регрессии

Strongly convex binary logistic regression. mu=0.2. m=1000, n=500.

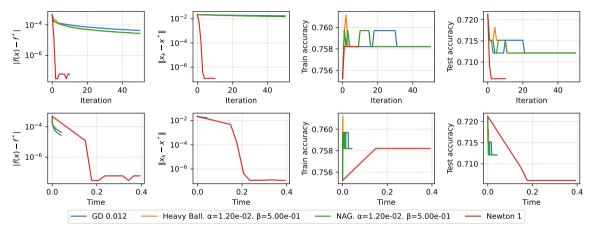


Рис. 9: Не меняя задачу, изменим начальную точку и наблюдаем квадратичную сходимость метода Ньютона. Однако, обратите внимание на время работы. Уже при небольшой размерности, метод Ньютона работает значительно дольше, чем градиентные методы.

### Задача нахождения аналитического центра многогранника

Найти точку  $x \in \mathbb{R}^n$ , которая максимизирует сумму логарифмов расстояний до границ политопа:


$$\max_{x} \sum_{i=1}^{m} \log(1-a_i^T x) + \sum_{j=1}^{n} \log(1-x_j^2)$$

или, эквивалентно, минимизирует:

$$\min_{x} - \sum_{i=1}^{m} \log(1 - a_i^T x) - \sum_{j=1}^{n} \log(1 - x_j^2)$$

при ограничениях: -  $a_i^Tx < 1$  для всех i=1,...,m, где  $a_i$  - строки матрицы  $A^T$  -  $|x_j| < 1$  для всех j=1,...,n Аналитический центр многогранника - это точка, которая максимально удалена от всех границ многогранника в смысле логарифмического барьера. Эта концепция широко используется в методах


внутренней точки для выпуклой оптимизации.



⊕ 0 a

## Задача нахождения аналитического центра многогранника


Analytical Center, m = 20, n = 100





## Задача нахождения аналитического центра многогранника

Analytical Center, m = 200, n = 1000





Важным свойством метода Ньютона является **аффинная инвариантность**. Пусть дана функция f и невырожденная матрица  $A \in \mathbb{R}^{n \times n}$ , пусть x = Ay, и пусть g(y) = f(Ay). Заметим, что  $\nabla g(y) = A^T \nabla f(x)$  и  $abla^2 q(y) = A^T 
abla^2 f(x) A$ . Шаги Ньютона на g выражаются как:

$$y_{k+1} = y_k - \left(\nabla^2 g(y_k)\right)^{-1} \nabla g(y_k)$$

Важным свойством метода Ньютона является **аффинная инвариантность**. Пусть дана функция f и невырожденная матрица  $A \in \mathbb{R}^{n \times n}$ , пусть x = Ay, и пусть g(y) = f(Ay). Заметим, что  $\nabla g(y) = A^T \nabla f(x)$  и  $\nabla^2 q(y) = A^T \nabla^2 f(x) A$ . Шаги Ньютона на q выражаются как:

$$y_{k+1} = y_k - \left(\nabla^2 g(y_k)\right)^{-1} \nabla g(y_k)$$

Раскрывая это, мы получаем:

$$y_{k+1} = y_k - \left(A^T \nabla^2 f(Ay_k) A\right)^{-1} A^T \nabla f(Ay_k)$$

Важным свойством метода Ньютона является **аффинная инвариантность**. Пусть дана функция f и невырожденная матрица  $A \in \mathbb{R}^{n \times n}$ , пусть x = Ay, и пусть g(y) = f(Ay). Заметим, что  $\nabla g(y) = A^T \nabla f(x)$  и  $\nabla^2 q(y) = A^T \nabla^2 f(x) A$ . Шаги Ньютона на q выражаются как:

$$y_{k+1} = y_k - \left(\nabla^2 g(y_k)\right)^{-1} \nabla g(y_k)$$

Раскрывая это, мы получаем:

$$y_{k+1} = y_k - \left(A^T \nabla^2 f(Ay_k) A\right)^{-1} A^T \nabla f(Ay_k)$$

Используя свойство обратной матрицы  $(AB)^{-1} = B^{-1}A^{-1}$ , это упрощается до:

$$\begin{aligned} y_{k+1} &= y_k - A^{-1} \left( \nabla^2 f(A y_k) \right)^{-1} \nabla f(A y_k) \\ A y_{k+1} &= A y_k - \left( \nabla^2 f(A y_k) \right)^{-1} \nabla f(A y_k) \end{aligned}$$

Важным свойством метода Ньютона является **аффинная инвариантность**. Пусть дана функция f и невырожденная матрица  $A \in \mathbb{R}^{n \times n}$ , пусть x = Ay, и пусть g(y) = f(Ay). Заметим, что  $\nabla g(y) = A^T \nabla f(x)$  и  $\nabla^2 q(y) = A^T \nabla^2 f(x) A$ . Шаги Ньютона на q выражаются как:

$$y_{k+1} = y_k - \left(\nabla^2 g(y_k)\right)^{-1} \nabla g(y_k)$$

Раскрывая это, мы получаем:

$$y_{k+1} = y_k - \left(A^T \nabla^2 f(Ay_k) A\right)^{-1} A^T \nabla f(Ay_k)$$

Используя свойство обратной матрицы  $(AB)^{-1} = B^{-1}A^{-1}$ , это упрощается до:

$$\begin{aligned} y_{k+1} &= y_k - A^{-1} \left( \nabla^2 f(A y_k) \right)^{-1} \nabla f(A y_k) \\ A y_{k+1} &= A y_k - \left( \nabla^2 f(A y_k) \right)^{-1} \nabla f(A y_k) \end{aligned}$$

Таким образом, правило обновления для x выглядит так:

$$x_{k+1} = x_k - \left(\nabla^2 f(x_k)\right)^{-1} \nabla f(x_k)$$

Важным свойством метода Ньютона является аффинная инвариантность. Пусть дана функция f и невырожденная матрица  $A \in \mathbb{R}^{n \times n}$ , пусть x = Ay, и пусть g(y) = f(Ay). Заметим, что  $\nabla g(y) = A^T \nabla f(x)$  и  $\nabla^2 g(y) = A^T \nabla^2 f(x) A$ . Шаги Ньютона на g выражаются как:

$$y_{k+1} = y_k - \left(\nabla^2 g(y_k)\right)^{-1} \nabla g(y_k)$$

Раскрывая это, мы получаем:

$$y_{k+1} = y_k - \left(A^T \nabla^2 f(Ay_k) A\right)^{-1} A^T \nabla f(Ay_k)$$

Используя свойство обратной матрицы  $(AB)^{-1}=B^{-1}A^{-1}$ , это упрощается до:

$$\begin{split} y_{k+1} &= y_k - A^{-1} \left( \nabla^2 f(A y_k) \right)^{-1} \nabla f(A y_k) \\ A y_{k+1} &= A y_k - \left( \nabla^2 f(A y_k) \right)^{-1} \nabla f(A y_k) \end{split}$$

Таким образом, правило обновления для  $\boldsymbol{x}$  выглядит так:

$$x_{k+1} = x_k - \left(\nabla^2 f(x_k)\right)^{-1} \nabla f(x_k)$$

Это показывает, что итерация метода Ньютона, не зависит от масштаба задачи. У градиентного спуска такого свойства нет!

### Плюсы:

• Квадратичная сходимость вблизи решения  $x^*$ 





#### Плюсы:

- ullet Квадратичная сходимость вблизи решения  $x^*$
- Аффинная инвариантность





#### Плюсы:

- Квадратичная сходимость вблизи решения  $x^*$
- Аффинная инвариантность
- Отсутствие параметров у метода





#### Плюсы:

- Квадратичная сходимость вблизи решения  $x^*$
- Аффинная инвариантность
- Отсутствие параметров у метода
- Сходимость можно сделать глобальной, если использовать демпфированный метод Ньютона (добавить процедуру линейного поиска и шага метода)





#### Плюсы:

- Квадратичная сходимость вблизи решения  $x^*$
- Аффинная инвариантность
- Отсутствие параметров у метода
- Сходимость можно сделать глобальной, если использовать демпфированный метод Ньютона (добавить процедуру линейного поиска и шага метода)

### Минусы:

• Необходимо хранить (обратный) гессиан на каждой итерации:  $\mathcal{O}(n^2)$  памяти





#### Плюсы:

- Квадратичная сходимость вблизи решения  $x^*$
- Аффинная инвариантность
- Отсутствие параметров у метода
- Сходимость можно сделать глобальной, если использовать демпфированный метод Ньютона (добавить процедуру линейного поиска и шага метода)

- Необходимо хранить (обратный) гессиан на каждой итерации:  $\mathcal{O}(n^2)$  памяти
- Необходимо решать линейные системы:  $\mathcal{O}(n^3)$  операций





#### Плюсы:

- Квадратичная сходимость вблизи решения  $x^*$
- Аффинная инвариантность
- Отсутствие параметров у метода
- Сходимость можно сделать глобальной, если использовать демпфированный метод Ньютона (добавить процедуру линейного поиска и шага метода)

- Необходимо хранить (обратный) гессиан на каждой итерации:  $\mathcal{O}(n^2)$  памяти
- Необходимо решать линейные системы:  $\mathcal{O}(n^3)$  операций
- Гессиан может быть вырожденным в  $x^*$



#### Плюсы:

- Квадратичная сходимость вблизи решения  $x^*$
- Аффинная инвариантность
- Отсутствие параметров у метода
- Сходимость можно сделать глобальной, если использовать демпфированный метод Ньютона (добавить процедуру линейного поиска и шага метода)

- Необходимо хранить (обратный) гессиан на каждой итерации:  $\mathcal{O}(n^2)$  памяти
- Необходимо решать линейные системы:  $\mathcal{O}(n^3)$  операций
- Гессиан может быть вырожденным в  $x^*$
- Гессиан может не быть положительно определенным  $\to$  направление  $-(f''(x))^{-1}f'(x)$  может не быть направлением спуска





# Квазиньютоновские методы





Пусть дана функция f(x) и точка  $x_0$ . Определим  $B_{arepsilon}(x_0)=\{x\in\mathbb{R}^n:d(x,x_0)=arepsilon^2\}$  как множество точек с расстоянием  $\varepsilon$  до  $x_0$ . Здесь мы предполагаем существование функции расстояния  $d(x,x_0)$ .

Пусть дана функция f(x) и точка  $x_0$ . Определим  $B_{\varepsilon}(x_0)=\{x\in\mathbb{R}^n:d(x,x_0)=\varepsilon^2\}$  как множество точек с расстоянием  $\varepsilon$  до  $x_0$ . Здесь мы предполагаем существование функции расстояния  $d(x,x_0)$ .

$$x^* = \arg\min_{x \in B_\varepsilon(x_0)} f(x)$$

Пусть дана функция f(x) и точка  $x_0$ . Определим  $B_{\varepsilon}(x_0) = \{x \in \mathbb{R}^n : d(x,x_0) = \varepsilon^2\}$  как множество точек с расстоянием  $\varepsilon$  до  $x_0$ . Здесь мы предполагаем существование функции расстояния  $d(x,x_0)$ .

$$x^* = \arg\min_{x \in B_\varepsilon(x_0)} f(x)$$

Далее, мы можем определить другое направление наискорейшего спуска в терминах минимизатора функции на сфере:

Пусть дана функция f(x) и точка  $x_0$ . Определим  $B_{\varepsilon}(x_0) = \{x \in \mathbb{R}^n : d(x,x_0) = \varepsilon^2\}$  как множество точек с расстоянием  $\varepsilon$  до  $x_0$ . Здесь мы предполагаем существование функции расстояния  $d(x,x_0)$ .

$$x^* = \arg\min_{x \in B_\varepsilon(x_0)} f(x)$$

Далее, мы можем определить другое направление наискорейшего спуска в терминах минимизатора функции на сфере:

$$s = \lim_{\varepsilon \to 0} \frac{x^* - x_0}{\varepsilon}$$

Пусть дана функция f(x) и точка  $x_0$ . Определим  $B_{\varepsilon}(x_0) = \{x \in \mathbb{R}^n : d(x,x_0) = \varepsilon^2\}$  как множество точек с расстоянием  $\varepsilon$  до  $x_0$ . Здесь мы предполагаем существование функции расстояния  $d(x,x_0)$ .

$$x^* = \arg\min_{x \in B_\varepsilon(x_0)} f(x)$$

Далее, мы можем определить другое направление наискорейшего спуска в терминах минимизатора функции на сфере:

$$s = \lim_{\varepsilon \to 0} \frac{x^* - x_0}{\varepsilon}$$

Предположим, что расстояние локально определяется некоторой метрикой A:

$$d(x,x_0) = (x-x_0)^\top A(x-x_0)$$

**⊕** ດ **ø** 

Пусть дана функция f(x) и точка  $x_0$ . Определим  $B_{\varepsilon}(x_0)=\{x\in\mathbb{R}^n:d(x,x_0)=\varepsilon^2\}$  как множество точек с расстоянием  $\varepsilon$  до  $x_0$ . Здесь мы предполагаем существование функции расстояния  $d(x,x_0)$ .

$$x^* = \arg\min_{x \in B_\varepsilon(x_0)} f(x)$$

Далее, мы можем определить другое направление наискорейшего спуска в терминах минимизатора функции на сфере:

$$s = \lim_{s \to 0} \frac{x^* - x_0}{s}$$

Предположим, что расстояние локально определяется некоторой метрикой A:

$$d(x, x_0) = (x - x_0)^{\top} A(x - x_0)$$

Далее рассмотрим первый порядок аппроксимации функции f(x) в окрестности точки  $x_0$ :

(1)



Теперь мы можем сформулировать задачу нахождения

st  $\delta x^{\top} A \delta x = \varepsilon^2$ 

 $\min_{\delta x \in \mathbb{R}^{\, \bowtie}} f(x_0 + \delta x)$ 

s, как это было сказано выше.

Пусть дана функция f(x) и точка  $x_0$ . Определим  $B_{\varepsilon}(x_0) = \{x \in \mathbb{R}^n : d(x,x_0) = \varepsilon^2\}$  как множество точек с расстоянием  $\varepsilon$  до  $x_0$ . Здесь мы предполагаем существование функции расстояния  $d(x, x_0)$ .

$$x^* = \arg\min_{x \in B_\varepsilon(x_0)} f(x)$$

функции на сфере:

Далее, мы можем определить другое направление

наискорейшего спуска в терминах минимизатора

$$s = \lim_{\varepsilon \to 0} \frac{x^* - x_0}{\varepsilon}$$

Предположим, что расстояние локально определяется некоторой метрикой A:

$$d(x, x_0) = (x - x_0)^{\mathsf{T}} A(x - x_0)$$

Далее рассмотрим первый порядок аппроксимации функции f(x) в окрестности точки  $x_0$ :

Теперь мы можем сформулировать задачу нахождения

st  $\delta x^{\top} A \delta x = \varepsilon^2$ 

st  $\delta x^{\top} A \delta x = \varepsilon^2$ 

 $\min_{\delta x \in \mathbb{R}^{\, \times}} f(x_0 + \delta x)$ 

 $\min_{\delta x \in \mathbb{R}^{\, \bowtie}} \nabla f(x_0)^{\top} \delta x$ 

s, как это было сказано выше.

Используя уравнение 1, получаем:

(1)

**⊕** ດ **ø** 

Пусть дана функция f(x) и точка  $x_0$ . Определим  $B_{\varepsilon}(x_0) = \{x \in \mathbb{R}^n : d(x,x_0) = \varepsilon^2\}$  как множество точек с расстоянием  $\varepsilon$  до  $x_0$ . Здесь мы предполагаем существование функции расстояния  $d(x, x_0)$ .

$$x^* = \arg\min_{x \in B_{\varepsilon}(x_0)} f(x)$$

функции на сфере:  $s = \lim_{x \to 0} \frac{x^* - x_0}{2}$ 

Далее, мы можем определить другое направление

наискорейшего спуска в терминах минимизатора

$$s = \lim_{\varepsilon \to 0} \frac{1}{\varepsilon}$$

некоторой метрикой A:

 $f o \min_{x, t, c, z} \phi_{t, v} \int_{\mathsf{KBa3WHsbotohogcKMe}}^{f o + \min_{x, t, c, z}} f(x_0 + \delta x) \approx f(x_0) + \nabla f(x_0)^{\top} \delta x$ 

$$d(x, x_0) = (x - x_0)^{\top} A(x - x_0)$$

Далее рассмотрим первый порядок аппроксимации функции f(x) в окрестности точки  $x_0$ :

Используя метод множителей Лагранжа:

Предположим, что расстояние локально определяется

s, как это было сказано выше.

Используя уравнение 1, получаем:

 $\delta x = -\frac{2\varepsilon^2}{\nabla f(x_0)^\top A^{-1} \nabla f(x_0)} A^{-1} \nabla f$ 

Теперь мы можем сформулировать задачу нахождения

st  $\delta x^{\top} A \delta x = \varepsilon^2$ 

st  $\delta x^{\top} A \delta x = \varepsilon^2$ 

 $\min_{\delta x \in \mathbb{R}^{\, \times}} f(x_0 + \delta x)$ 

 $\min_{\delta x \in \mathbb{R}^K} \nabla f(x_0)^\top \delta x$ 

(1)





### Идея адаптивных метрик Пусть дана функция f(x) и точка $x_0$ . Определим

 $B_{\varepsilon}(x_0) = \{x \in \mathbb{R}^n : d(x,x_0) = \varepsilon^2\}$  как множество точек с расстоянием  $\varepsilon$  до  $x_0$ . Здесь мы предполагаем существование функции расстояния  $d(x, x_0)$ .

$$x^* = \arg\min_{x \in B_{\varepsilon}(x_0)} f(x)$$

Далее, мы можем определить другое направление

наискорейшего спуска в терминах минимизатора

функции на сфере:

$$s = \lim_{\varepsilon \to 0} \frac{x^* - x_0}{\varepsilon}$$

некоторой метрикой A:

 $f o \min_{x,y,z} \geqslant_{\mathbb{Q}_{\mathsf{LV}}} f(x_0 + \delta x) pprox f(x_0) + \nabla f(x_0)^{ op} \delta x$  Квазиньютоновские методы

$$d(x, x_0) = (x - x_0)^{\top} A(x - x_0)$$

Далее рассмотрим первый порядок аппроксимации функции f(x) в окрестности точки  $x_0$ :

(1)

Предположим, что расстояние локально определяется

Используя уравнение 1, получаем:

s, как это было сказано выше.

Используя метод множителей Лагранжа:

st  $\delta x^{\top} A \delta x = \varepsilon^2$ 

Теперь мы можем сформулировать задачу нахождения

st  $\delta x^{\top} A \delta x = \varepsilon^2$ 

 $\min_{\delta x \in \mathbb{R}^{\, \times}} f(x_0 + \delta x)$ 

 $\min_{\delta x \in \mathbb{R}^K} \nabla f(x_0)^\top \delta x$ 

 $\delta x = -\frac{2\varepsilon^2}{\nabla f(x_0)^\top A^{-1} \nabla f(x_0)} A^{-1} \nabla f$ 

Новое направление наискорейшего спуска:  $A^{-1}\nabla f(x_0)$ .

Пусть дана функция f(x) и точка  $x_0$ . Определим  $B_{\varepsilon}(x_0) = \{x \in \mathbb{R}^n : d(x,x_0) = \varepsilon^2\}$  как множество

точек с расстоянием 
$$\varepsilon$$
 до  $x_0$ . Здесь мы предполагаем существование функции расстояния  $d(x,x_0)$ . 
$$x^*=\arg\min_{x\in B_+(x_0)}f(x)$$

функции на сфере: 
$$x^* - x$$

Далее, мы можем определить другое направление

наискорейшего спуска в терминах минимизатора

$$\frac{-x_0}{\varepsilon}$$

Предположим, что расстояние локально определяется

рй 
$$A$$
:

 $d(x, x_0) = (x - x_0)^{\top} A(x - x_0)$ 

 $f o \min_{x,y,z} \geqslant_{\text{LLV}} f(x_0 + \delta x) pprox f(x_0) + \nabla f(x_0)^{ op} \delta x$  Квазиньютоновские методы

 $A^{-1}\nabla f(x_0)$ .

s.t. 
$$\delta x^{ op} A \delta x = arepsilon^2$$
vя метод множителей Лаг

гессиан как матрицу метрик.

s, как это было сказано выше.

Используя уравнение 1, получаем:

Используя метод множителей Лагранжа:

Теперь мы можем сформулировать задачу нахождения

st  $\delta x^{\top} A \delta x = \varepsilon^2$ 

 $\min_{\delta x \in \mathbb{R}^{k}} f(x_0 + \delta x)$ 

 $\min_{\delta x \in \mathbb{R}^K} \nabla f(x_0)^\top \delta x$ 

кителей Лагранжа: 
$$2\varepsilon^2$$

$$\frac{2\varepsilon^2}{\sqrt{14-1}\nabla^4(\tau)}A^{-1}\nabla$$

$$\delta x = -\frac{2\varepsilon^2}{\nabla f(x_0)^\top A^{-1} \nabla f(x_0)} A^{-1} \nabla f$$

$$\delta x = -\frac{2\varepsilon}{\nabla f(x_0)^{\top} A^{-1} \nabla f(x_0)} A^{-1} \nabla$$

$$abla f(x_0)^{ op}A^{-1}
abla f(x_0)$$
 Новое направление наискорейшего спуска :

$$A^{-1} \vee f(x_0).$$
 Действительно, если пространство изотропно и  $A=I$  ,

⊕ n ø

Далее рассмотрим первый порядок аппроксимации

функции f(x) в окрестности точки  $x_0$ :

 $s = \lim_{x \to 0} \frac{x^* - x_0}{2}$ 

Для классической задачи безусловной оптимизации  $f(x) o \min_{x \in \mathbb{R}^n}$  общий алгоритм итерационного метода записывается как:

$$x_{k+1} = x_k + \alpha_k d_k$$



Для классической задачи безусловной оптимизации  $f(x) o \min_{x \in \mathbb{R}^n}$  общий алгоритм итерационного метода записывается как:

$$x_{k+1} = x_k + \alpha_k d_k$$

В методе Ньютона направление  $d_k$  (направление Ньютона) устанавливается решением линейной системы на каждом шаге:

$$B_k d_k = -\nabla f(x_k), \quad B_k = \nabla^2 f(x_k)$$



Для классической задачи безусловной оптимизации  $f(x) o \min_{x \in \mathbb{R}^n}$  общий алгоритм итерационного метода записывается как:

$$x_{k+1} = x_k + \alpha_k d_k$$

В методе Ньютона направление  $d_k$  (направление Ньютона) устанавливается решением линейной системы на каждом шаге:

$$B_k d_k = -\nabla f(x_k), \quad B_k = \nabla^2 f(x_k)$$

т.е. на каждой итерации необходимо вычислить гессиан и градиент и решить линейную систему.





Для классической задачи безусловной оптимизации  $f(x) o \min_{x \in \mathbb{R}^n}$  общий алгоритм итерационного метода записывается как:

$$x_{k+1} = x_k + \alpha_k d_k$$

В методе Ньютона направление  $d_k$  (направление Ньютона) устанавливается решением линейной системы на каждом шаге:

$$B_k d_k = -\nabla f(x_k), \quad B_k = \nabla^2 f(x_k)$$

т.е. на каждой итерации необходимо вычислить гессиан и градиент и решить линейную систему.

Обратите внимание, что если мы возьмем единичную матрицу  $B_k=I_n$  в качестве  $B_k$  на каждом шаге, мы получим точно метод градиентного спуска.

Обший алгоритм квазиньютоновских методов основан на выборе матрицы  $B_k$  так, чтобы она в некотором смысле стремилась к истинному значению гессиана  $\nabla^2 f(x_k)$  при  $k \to \infty$ .



# Шаблон квазиньютоновского метода

Пусть  $x_0 \in \mathbb{R}^n$ ,  $B_0 \succ 0$ . Для k=1,2,3,..., повторяем:

1. Решить  $B_k d_k = -\nabla f(x_k)$ 

## Шаблон квазиньютоновского метода

Пусть  $x_0 \in \mathbb{R}^n$ ,  $B_0 \succ 0$ . Для k = 1, 2, 3, ..., повторяем:

- 1. Решить  $B_k d_k = -\nabla f(x_k)$
- 2. Обновить  $x_{k+1} = x_k + \alpha_k d_k$

# Шаблон квазиньютоновского метода

Пусть  $x_0 \in \mathbb{R}^n$ ,  $B_0 \succ 0$ . Для k = 1, 2, 3, ..., повторяем:

- 1. Решить  $B_k d_k = -\nabla f(x_k)$
- 2. Обновить  $x_{k+1} = x_k + \alpha_k d_k$ 3. Вычислить  $B_{k+1}$  из  $B_k$

Пусть  $x_0 \in \mathbb{R}^n$ ,  $B_0 \succ 0$ . Для k=1,2,3,..., повторяем:

- 1. Решить  $B_k d_k = -\nabla f(x_k)$
- 2. Обновить  $x_{k+1}=x_k+\alpha_k d_k$  3. Вычислить  $B_{k+1}$  из  $B_k$

Пусть  $x_0 \in \mathbb{R}^n$ ,  $B_0 \succ 0$ . Для k = 1, 2, 3, ..., повторяем:

- 1. Решить  $B_k d_k = -\nabla f(x_k)$
- 2. Обновить  $x_{k+1} = x_k + \alpha_k d_k$
- 3. Вычислить  $B_{k+1}$  из  $B_k$

Разные квазиньютоновские методы реализуют шаг 3 по-разному. Мы скоро увидим, что обычно мы можем вычислить  $(B_{k+1})^{-1}$  из  $(B_k)^{-1}$ .

Пусть  $x_0 \in \mathbb{R}^n$ ,  $B_0 \succ 0$ . Для k = 1, 2, 3, ..., повторяем:

- 1. Решить  $B_k d_k = -\nabla f(x_k)$
- 2. Обновить  $x_{k+1} = x_k + \alpha_k d_k$
- 3. Вычислить  $B_{\nu+1}$  из  $B_{\nu}$

Разные квазиньютоновские методы реализуют шаг 3 по-разному. Мы скоро увидим, что обычно мы можем вычислить  $(B_{k+1})^{-1}$  из  $(B_k)^{-1}$ .

**Основная идея:** Поскольку  $B_{l}$ , уже содержит информацию о гессиане, используем подходящее обновление матрицы для формирования  $B_{k+1}$ .



Пусть  $x_0 \in \mathbb{R}^n$ ,  $B_0 \succ 0$ . Для k = 1, 2, 3, ..., повторяем:

- 1. Решить  $B_k d_k = -\nabla f(x_k)$
- 2. Обновить  $x_{k+1} = x_k + \alpha_k d_k$
- 3. Вычислить  $B_{k+1}$  из  $B_k$

Разные квазиньютоновские методы реализуют шаг 3 по-разному. Мы скоро увидим, что обычно мы можем вычислить  $(B_{k+1})^{-1}$  из  $(B_k)^{-1}$ .

**Основная идея:** Поскольку  $B_k$  уже содержит информацию о гессиане, используем подходящее обновление матрицы для формирования  $B_{k+1}$ .

**Разумное требование для**  $B_{k+1}$  (вдохновленное методом секущих):

$$\begin{split} \nabla f(x_{k+1}) - \nabla f(x_k) &= B_{k+1}(x_{k+1} - x_k) = B_{k+1}d_k\\ \Delta y_k &= B_{k+1}\Delta x_k \end{split}$$



Пусть  $x_0 \in \mathbb{R}^n$ ,  $B_0 \succ 0$ . Для k = 1, 2, 3, ..., повторяем:

- 1. Решить  $B_k d_k = -\nabla f(x_k)$
- 2. Обновить  $x_{k+1} = x_k + \alpha_k d_k$
- 3. Вычислить  $B_{k+1}$  из  $B_k$

Разные квазиньютоновские методы реализуют шаг 3 по-разному. Мы скоро увидим, что обычно мы можем вычислить  $(B_{k+1})^{-1}$  из  $(B_k)^{-1}$ .

**Основная идея:** Поскольку  $B_k$  уже содержит информацию о гессиане, используем подходящее обновление матрицы для формирования  $B_{k+1}$ .

**Разумное требование для**  $B_{k+1}$  (вдохновленное методом секущих):

$$\begin{split} \nabla f(x_{k+1}) - \nabla f(x_k) &= B_{k+1}(x_{k+1} - x_k) = B_{k+1}d_k \\ \Delta y_k &= B_{k+1}\Delta x_k \end{split}$$

Помимо уравнения секущей, мы хотим:

•  $B_{k+1}$  симметричная

⊕ C @

Пусть  $x_0 \in \mathbb{R}^n$ ,  $B_0 \succ 0$ . Для k = 1, 2, 3, ..., повторяем:

- 1. Решить  $B_k d_k = -\nabla f(x_k)$
- 2. Обновить  $x_{k+1} = x_k + \alpha_k d_k$
- 3. Вычислить  $B_{k+1}$  из  $B_k$

Разные квазиньютоновские методы реализуют шаг 3 по-разному. Мы скоро увидим, что обычно мы можем вычислить  $(B_{k+1})^{-1}$  из  $(B_k)^{-1}$ .

**Основная идея:** Поскольку  $B_k$  уже содержит информацию о гессиане, используем подходящее обновление матрицы для формирования  $B_{k+1}$ .

**Разумное требование для**  $B_{k+1}$  (вдохновленное методом секущих):

$$\begin{split} \nabla f(x_{k+1}) - \nabla f(x_k) &= B_{k+1}(x_{k+1} - x_k) = B_{k+1}d_k \\ \Delta y_k &= B_{k+1}\Delta x_k \end{split}$$

Помимо уравнения секущей, мы хотим:

- $B_{k+1}$  симметричная
- $B_{k+1}$  близка к  $B_k$



Пусть  $x_0 \in \mathbb{R}^n$ ,  $B_0 \succ 0$ . Для k = 1, 2, 3, ..., повторяем:

- 1. Решить  $B_k d_k = -\nabla f(x_k)$
- 2. Обновить  $x_{k+1} = x_k + \alpha_k d_k$
- 3. Вычислить  $B_{k+1}$  из  $B_k$

Разные квазиньютоновские методы реализуют шаг 3 по-разному. Мы скоро увидим, что обычно мы можем вычислить  $(B_{k+1})^{-1}$  из  $(B_k)^{-1}$ .

**Основная идея:** Поскольку  $B_k$  уже содержит информацию о гессиане, используем подходящее обновление матрицы для формирования  $B_{k+1}$ .

**Разумное требование для**  $B_{k+1}$  (вдохновленное методом секущих):

$$\begin{split} \nabla f(x_{k+1}) - \nabla f(x_k) &= B_{k+1}(x_{k+1} - x_k) = B_{k+1}d_k \\ \Delta y_k &= B_{k+1}\Delta x_k \end{split}$$

Помимо уравнения секущей, мы хотим:

- $B_{k+1}$  симметричная
- $B_{k+1}$  близка к  $B_k$
- $B_k \succ 0 \Rightarrow B_{k+1} \succ 0$



Попробуем обновление вида:

$$B_{k+1} = B_k + auu^T$$



Попробуем обновление вида:

$$B_{k+1} = B_k + auu^T$$

Уравнение секущей  $B_{k+1}d_k=\Delta y_k$  дает:

$$(au^Td_k)u=\Delta y_k-B_kd_k$$



Попробуем обновление вида:

$$B_{k+1} = B_k + auu^T$$

Уравнение секущей  $B_{k+1}d_k=\Delta y_k$  дает:

$$(au^Td_k)u = \Delta y_k - B_k d_k$$

Это верно только если u является кратным  $\Delta y_k - B_k d_k$ . Положив  $u = \Delta y_k - B_k d_k$ , мы решаем уравнение,

$$a = \frac{1}{(\Delta y_k - B_k d_k)^T d_k},$$





Попробуем обновление вида:

$$B_{k+1} = B_k + auu^T$$

Уравнение секущей  $B_{k+1}d_k = \Delta y_k$  дает:

$$(au^Td_k)u = \Delta y_k - B_kd_k$$

Это верно только если u является кратным  $\Delta y_k - B_k d_k$ . Положив  $u = \Delta y_k - B_k d_k$ , мы решаем уравнение,

$$a = \frac{1}{(\Delta y_k - B_k d_k)^T d_k},$$

что приводит к

$$B_{k+1} = B_k + \frac{(\Delta y_k - B_k d_k)(\Delta y_k - B_k d_k)^T}{(\Delta y_k - B_k d_k)^T d_k}$$

Это называется симметричным одноранговым (SR1) обновлением или методом Бройдена.



## Симметричное одноранговое обновление с инверсией

Как мы можем решить

$$B_{k+1}d_{k+1} = -\nabla f(x_{k+1}),$$

чтобы сделать следующий шаг? Помимо распространения  $B_k$  на  $B_{k+1}$ , давайте распространим инверсии, т.е.  $C_{k} = B_{k}^{-1}$  на  $C_{k+1} = (B_{k+1})^{-1}$ .

#### Формула Шермана-Моррисона:

Формула Шермана-Моррисона утверждает:

$$(A + uv^T)^{-1} = A^{-1} - \frac{A^{-1}uv^TA^{-1}}{1 + v^TA^{-1}u}$$

Таким образом, для SR1 обновления, обратная матрица также легко обновляется:

$$C_{k+1} = C_k + \frac{(d_k - C_k \Delta y_k)(d_k - C_k \Delta y_k)^T}{(d_k - C_k \Delta y_k)^T \Delta y_k}$$

В общем, SR1 прост и дешев, но у него есть ключевой недостаток: он не сохраняет положительную определенность.

# Обновление Давидона-Флетчера-Пауэлла

Мы могли бы продолжить ту же идею для обновления обратной матрицы C:

$$C_{k+1} = C_k + auu^T + bvv^T.$$

# Обновление Давидона-Флетчера-Пауэлла

Мы могли бы продолжить ту же идею для обновления обратной матрицы C:

$$C_{k+1} = C_k + auu^T + bvv^T.$$

Умножая на  $\Delta y_k$ , используя уравнение секущей  $d_k = C_k \Delta y_k$  и решая для  $a,\,b$ , получаем:

$$C_{k+1} = C_k - \frac{C_k \Delta y_k \Delta y_k^T C_k}{\Delta y_k^T C_k \Delta y_k} + \frac{d_k d_k^T}{\Delta y_k^T d_k}$$

#### Применение формулы Вудбери

Вудбери показывает:

$$B_{k+1} = \left(I - \frac{\Delta y_k d_k^T}{\Delta y_k^T d_k}\right) B_k \left(I - \frac{d_k \Delta y_k^T}{\Delta y_k^T d_k}\right) + \frac{\Delta y_k \Delta y_k^T}{\Delta y_k^T d_k}$$

Это обновление Давидона-Флетчера-Пауэлла (DFP). Также дешево:  $O(n^2)$ , но сохраняет положительную определенность. Не так популярно, как BFGS.

## Обновление Бройдена-Флетчера-Гольдштейна-Шенно

Попробуем теперь двухранговое обновление:

$$B_{k+1} = B_k + auu^T + bvv^T.$$



## Обновление Бройдена-Флетчера-Гольдштейна-Шенно

Попробуем теперь двухранговое обновление:

$$B_{k+1} = B_k + auu^T + bvv^T.$$

Уравнение секущей  $\Delta y_k = B_{k+1} d_k$  дает:

$$\Delta y_k - B_k d_k = (au^T d_k) u + (bv^T d_k) v$$



## Обновление Бройдена-Флетчера-Гольдштейна-Шенно

Попробуем теперь двухранговое обновление:

$$B_{k+1} = B_k + auu^T + bvv^T.$$

Уравнение секущей  $\Delta y_k = B_{k+1} d_k$  дает:

$$\Delta y_k - B_k d_k = (au^T d_k) u + (bv^T d_k) v$$

Положив  $u=\Delta y_k$ ,  $v=B_kd_k$  и решая для a, b, получаем:

$$B_{k+1} = B_k - \frac{B_k d_k d_k^T B_k}{d_k^T B_k d_k} + \frac{\Delta y_k \Delta y_k^T}{d_k^T \Delta y_k}$$

Это обновление Бройдена-Флетчера-Гольдштейна-Шенно (BFGS).



## Обновление Бройдена-Флетчера-Гольдштейна-Шенно с инверсией

#### Формула Вудбери

Формула Вудбери, обобщение формулы Шермана-Моррисона, дается как:

$$(A+UCV)^{-1}=A^{-1}-A^{-1}U(C^{-1}+VA^{-1}U)^{-1}VA^{-1}$$

## Обновление Бройдена-Флетчера-Гольдштейна-Шенно с инверсией

#### Формула Вудбери

Формула Вудбери, обобщение формулы Шермана-Моррисона, дается как:

$$(A+UCV)^{-1}=A^{-1}-A^{-1}U(C^{-1}+VA^{-1}U)^{-1}VA^{-1}$$

Примененная к нашему случаю, мы получаем двухранговое обновление на обратной матрице C:

$$C_{k+1} = C_k + \frac{(d_k - C_k \Delta y_k) d_k^T}{\Delta y_k^T d_k} + \frac{d_k (d_k - C_k \Delta y_k)^T}{\Delta y_k^T d_k} - \frac{(d_k - C_k \Delta y_k)^T \Delta y_k}{(\Delta y_k^T d_k)^2} d_k d_k^T$$

$$C_{k+1} = \left(I - \frac{d_k \Delta y_k^T}{\Delta y_k^T d_k}\right) C_k \left(I - \frac{\Delta y_k d_k^T}{\Delta y_k^T d_k}\right) + \frac{d_k d_k^T}{\Delta y_k^T d_k}$$

Эта формулировка обеспечивает, что обновление BFGS, оставаясь достаточно общим, сохраняет вычислительную эффективность и требует  $O(n^2)$  операций. Важно, что обновление BFGS сохраняет положительную определенность:  $B_k \succ 0 \Rightarrow B_{k+1} \succ 0$ . Эквивалентно,  $C_k \succ 0 \Rightarrow C_{k+1} \succ 0$ 

# Код

• Открыть в Colab





## Код

- Открыть в Colab
- Сравнение квазиньютоновских методов



## Код

- Открыть в Colab
- Сравнение квазиньютоновских методов
- Некоторые практические замечания о методе Ньютона

